现在是 Agent 工程项目，尚未形成 Agentic RL

判断关键：执行得到的奖励，是否真正进入学习算法并更新后续的决策策略。

01 现在已有：运行闭环 + 评测与配置改进闭环

用户问题
统一对话入口
绑定身份与上下文

→

模型规划
选择已批准工具
有界多步决策

→

工具执行
数仓 / 正文 / 检索
Python / SQL 算数字

→

校验与保存
Schema 与证据校验
逐工具持久化轨迹

→

反馈与评测
错例 / 冻结数据集
候选与双基线回放

→

审批后激活
当前模型 / Prompt预设
版本绑定与回滚

反馈、Memory、工具重试、人工改 Prompt，都不能单独证明系统在做强化学习。

02 Agentic RL 的学习环：以下为待建设方案

冻结任务与环境
固定新闻 / 指标快照
保证可复现、无未来信息

→

采样多步轨迹
观察 → 动作 → 工具反馈
绑定策略、数据、工具版本

→

奖励与信用分配
结果正确性 + 过程信号
把成败信号关联到决策

→

RL 策略更新
学习算法优化策略
产出权重 / LoRA / 控制器

→

新策略版本
留出任务独立评测
人工审批后接入运行时

更新后的策略重新执行任务；评测和审批底座可复用，现有日志仍需补成训练契约。

最小试点：让 Agent 学习如何找齐证据

观察 问题、已知新闻、已取得证据、剩余工具预算

动作 检索、读原文、补证据、结束或说明证据不足

奖励 事实与引用正确；扣除无效调用及时间成本

护栏 数字由 Python/SQL 核验；越权与编造直接拦截

同一任务探索多条路径，再用未见过的新闻主线检验泛化。

需要补的能力与现有边界

可训练策略 + 奖励契约 + 采样执行器 + Trainer + 版本回接

只有推理 API 还不能训练大模型；需要训练接口、可控权重，
或独立可训练的决策控制器。RL 不要求全量训练大模型。

保留 Python/SQL 权威计算、数据权限、人工审批与发布边界。
Agent 自动提交 SFT 实验，也不自动等于 Agent 自身经过 RL。

依据：当前工作区 conversation / data_loop / InferencePort；PROJECT_CONTEXT；TAOTIAN。仅作定位与设计说明。

研究参考：Agent Lightning（执行与训练解耦） | RAGEN（多轮轨迹策略优化）