NEWSAGENT / BGE RETRIEVAL / 2026-10-16

BGE负责找相关报道，为分析与阅读补充材料

bge-large-zh-v1.5 · 1024维 · HNSW离线索引 · v2构建账本：20,187篇新闻 / 50,252个片段

① 离线准备：把新闻变成可检索的向量库

新闻原文 → 确定性切片 → BGE编码 → HNSW快照

新闻原文
版本、来源与文件哈希

确定性切片
新增正文800字 / 重叠80字

BGE编码
同一模型生成归一化向量

HNSW快照
保存片段、向量与索引文件

② 热点分析主链：先算热点，再用BGE找背景，最后分析

SQL / Python → news_id取原文 → BGE + HNSW → Python业务重排 → 分析模型 + 校验

SQL / Python
候选、指标、权威热度

news_id取原文
精确取得这篇新闻正文

BGE + HNSW
标题/摘要编码，召回相关片段

Python业务重排
主体、事件、关键词、时间

分析模型 + 校验
证据白名单 → 保存报告

通常每篇召回20个候选，经排源、去重和重排后保留最多3篇；结果进入 HotNewsAnalysisInput.related_news。

③ 聊天中的两种用法：共享索引，输出去向不同

自动相关新闻卡片

已完成热点 → 取前3条标题 → BGE召回
每条最多3篇、片段最多600字 → 检查点 → SSE/页面

仅作展示；不回写报告，不进入当前轮聊天规划模型

显式知识检索工具

输入“检索第一条的相关新闻”或“检索AI芯片相关新闻”
search_knowledge → BGE编码/检索 → 工具片段 → 对话

显式工具结果可进入模型上下文，用于回答与引用

它带来的效果

找到语义相近的背景

表达不同也可召回同主题材料
再通过主体/事件规则减少误关联

扩大证据范围

120篇演示新闻可关联更大语料
只传有限片段，保留来源与版本

让人能核对与继续阅读

页面展示相关新闻片段与可用链接
工具结果保存后可刷新恢复

效果边界与当前TODO

BGE相似分数不等于热度、事实真伪或相关概率；当前没有严格按分析时点过滤发布日期，历史窗口可能召回后来报道。
自动卡片超时会降级保留热点结果；当前分析模型仍为本地规则替身。召回相关性、日期一致性与业务收益尚未量化验收。

配置：knowledge-search.incremental-20261014-v2.yml；核心：bge_snapshot / hot_news_enrichment / related_articles / tools。

验证入口：test_bge_snapshot_index、test_bge_snapshot_wiring、test_conversation_article_delivery；接线测试通过不代表召回质量。