NewsAgent 高并发 × 多租户

目标：10 个编辑部/业务团队，约 100 位活跃用户 | 代码核对：2026-10-15

可信身份 tenant / user / roles → **有界准入** 团队公平 + 等待上限 → **Python / Temporal** 会话执行与持久任务 → **资源配额** 模型 / SQL / 向量 → **事实与交付** PostgreSQL / 报告 / SSE

01 先算资源需求，再决定扩容

100 活跃用户 ≠ 100 同时执行 ≠ 100 模型调用
读报告 / 新建热点 / 写作 / 入库与评测，成本各不同。

假设每人 1 轮/分钟，每轮 3 次模型，每次 4 秒
约 1.67 轮/秒 → 5 次调用/秒 → 平均 20 个模型在途

仅为容量算例；还需加压缩、重试、后台和突发余量。

02 数据所有权与资源配额分开定义

平台：获准共享的新闻正文/索引，可复用但需显式授权。
团队：行为聚合、热点报告、任务、规则与审批作用域。
个人：会话、摘要、私人 Memory 与个人运营策略。

个人策略 → 候选/评测 → 人工审核 → 团队共享版本

共享策略仍待设计；现有 Memory 晋升保持个人作用域。

P0 统一入口身份

旧写作 REST / 进度入口仍读身份 Header；需接入已有 Principal，并验证网关信任链。

P1 统一共享额度

热点/检索限额主要在单进程；聊天、写作、压缩、入库仍争用模型与 Embedding。

P1 控制池与状态

每个 Database 池最大 40 连接，须按所有实例求和；重连/重试不能重复执行或覆盖终态。

后续评测集：固定夹具 + 场景负载 + 确定性判据 + 分租户报告

隔离：跨团队 / 同团队他人 / 伪造身份
一致：重复请求 / 同窗口与版本 / 撤权后派发
公平：均衡 10×10 / 噪声 55+9×5 / 长短混合
容量：阶梯并发 / 100 人突发 / 后台叠加
恢复：断线重连 / Worker 崩溃 / 2→4 副本
依赖：模型 429与超时 / PG与Redis / 索引更正撤稿

硬门槛：泄漏=0、重复副作用=0、旧执行覆盖=0；性能按每团队 P95、拒绝率、业务达成率验收。

历史边界：10/09 单租户 100 次突发，66 完成、34 model_unavailable；未证明供应商 429 或企业容量。

本轮为只读审计与评测设计；确定性替身测工程语义，真实依赖测容量，真实模型另测质量。