评测：从真实链路到可追溯证据

已交付专用 Skill · 8类链路地图 · 冻结规格 · 可执行入口 · 失败与人工门禁

01 先选评测对象：把工程合同、模型质量、集成和运营效果分别证明

1 采集与入库
URL → 正文/元数据 → 切片/Embedding
检查完整性、版本、accepted → ready

2 检索与索引
query → 三层召回 → 有效性过滤/重排
资产 / token覆盖 / ANN / 人工语义分报

3 SQL与权威指标
问题 → 受限Intent → 只读SQL → 指标
身份、窗口、口径、哈希与同run绑定

4 热点解释
指标/证据 → 模型 → Schema/Validator
主驱动、引用、数字、局限和硬违规

5 对话与记忆
多轮 → 工具/checkpoint → 持久化/SSE
幂等、恢复、摘要、隔离与确认边界

6 数据分析
可信run → 固定引擎 → Decimal结果
完整上榜子集、可比窗口、独立口径oracle

7 研究写作
研究 → 人工节点 → 写作/审校 → 终稿
事实、数字、引用；发布仍需独立动作

8 Data Loop
冻结风险层 → 对照回放 → 确定性Gate
当前/候选/可选上一实验 → 人工评审

02 严格执行链：前一阶段没有证据，就不替下一阶段宣告成功

01 冻结规格 — 范围 / 样本 / 哈希；版本 / oracle / 预算

→ **02 合同回归** — 数据与计算先校验；不自动读dotenv

→ **03 业务执行** — 复用Service/Workflow；真实ID与持久终态

→ **04 确定性评分** — 固定分母 / 独立标签；分组 / 失败不丢弃

→ **05 门禁判定** — 实际Policy / 双基线；阈值来源必须明确

→ **06 人工评审** — 提交证据与建议；Skill不自行批准

03 三条硬边界：测试通过不能越级成为质量或上线结论

分析回放 ≠ 检索效果
固定analysis_input不重新取数/召回/重排；
只改Bundle版本，不证明真实参数变化。

ANN一致 ≠ 新闻相关
近似邻域工程探针不等于用户问句质量；
人工草稿未盲标，语义验收就是blocked。

Gate通过 ≠ 自行上线
人工approve后原Workflow可能继续激活；
评测Skill停止在评审材料，不代替批准。

本轮交付验证

138 + 89 项本地合同测试通过 | 6个离线入口完成 | 2个独立场景试用通过

契约 passed / failed / blocked / not_run 分目标报告；本轮未调用企业模型、未变更生产配置。

入口：$newsagent-evaluation · 项目源：skills/newsagent-evaluation/SKILL.md · 证据：output/evaluation-skill-20261016/