先让 Agent 学会找齐证据，再验证训练是否有收益

第一版冻结生成模型、Embedding 与底层检索规则；只训练多步决策控制器，不执行生产变更。

A 运行环：把学习范围限定在只读证据收集

问题与观察
已知新闻 / 已见候选
证据缺口估计 / 剩余预算

→

可学习控制器
线性 softmax 策略
选择下一项获准动作

→

受控工具执行
模板查询 / 读取精确正文
跨来源补证 / 去重

→

证据包
news_id / 内容版本 / 哈希
引用片段 / 时点 / 不足说明

→

固定模型与校验
依据证据表达
Python / SQL 核验数字

工具结果形成下一步观察；金标只供奖励侧使用，不进入控制器。

B 学习环：在冻结环境重新执行动作，采样新轨迹

任务与环境冻结
新闻主线 / 语料成员 / 时点
正文 + 索引 + 工具版本

→

策略采样与记录
观察 / 掩码 / 动作概率
结果哈希 / 成本 / 终止状态

→

独立奖励计算
人工事实与证据标注
质量收益 - 调用成本

→

REINFORCE 更新
NumPy 离线训练小策略
每轮用当前策略重新采样

→

策略资产与验收
参数 SHA + 训练谱系
留出集 → 影子 → 人工批准

现有分析输入回放已固定证据，无法衡量新检索动作；必须新增完整检索 episode 环境和独立策略资产。

数据先于训练

先校准现有36题草稿，再扩展人工标注。
训练 / 验证 / 测试按时间与事件组隔离。
“无答案”需核对冻结语料范围。
新增未判证据先补标，不能默认负例。

冻结当时可见的正文版本与索引；仅过滤发布时间，不能排除事后更正内容泄漏。

奖励示例，待试标校准

证据充分、关键事实被支持	+1
错误 / 无据结论	-1
确实无答案且正确说明不足	+0.5
可回答却直接退出	-0.5
每次有效工具调用成本	-0.02

越权 / 未来证据由硬门禁拦截；
空输出、超时单列失败，不从分母删除。

实现顺序与放行条件

P0 人工标注 + 冻结小范围环境
P1 只读执行器 + 规则 / 固定流程基线
P2 真实参数更新 + 留出事件独立评测
P3 影子比对 + 人工审核后有限启用

同预算比较：有据正确覆盖、错误率、
正确拒答率、调用量与端到端延迟。
影子模式不改变用户答复，不在线探索。

拟新增：contracts / environment / executor / controller / trainer / evaluator / registry；生产默认关闭，训练入口离线隔离。

研究：REINFORCE（Williams, 1992） · Search-R1（2025） · Agent Lightning（2025） | 首轮只评证据收集能力。