现有链路　演练分配

向量召回架构与冷温热分层

现有资产：单库 HNSW；分层演练与在线迁移独立说明。数量单位：新闻篇数 / 向量切片数。

1 向量构建：新增正文编码，合并后重建整张 HNSW 图

继承 v1：12,728 篇 / 38,026 片
旧切片、旧向量保持原版本

真实新闻输入
新增 7,459 篇
公开正文 + 标题 + 来源 + 发布时间
冻结 manifest / 哈希校验

→ **确定性切片**
新增 12,226 片
正文 800 字符 / 重叠 80 字符
每片重复标题、来源与时间头

→ **BGE-large-zh-v1.5**
1,024 维
L2 归一化 / 存储 float32
模型上限 512 token，需关注截断

→ **单库 HNSW 索引 / 只读快照**
20,187 篇 / 50,252 片
IP 内积 / M=32 / efConstruction=200
label = 切片文件行号；HOT 是路由标记

新增只计算新新闻的向量；HNSW 使用全部向量重新构建。该快照拒绝写入和删除，不承担在线内容更正。

2 应用召回：当前 BGE 路径只有单一 HOT 索引

业务入口
聊天 search_knowledge
热点关联：标题 + 摘要

→ **查询 Embedding**
配套 BGE + 查询前缀
1024 维 / 归一化

→ **HNSW 搜索**
起始候选池 200 片
ef = max(256, 当前池大小)

→ **过滤与排名融合**
排除源新闻 / 按 news_id 去重
不足则扩池 / RRF 排名分数

→ **业务输出**
热点：规则重排 → 证据 → 报告
聊天：工具检查点 → SSE / 页面

索引工厂选择 bge_snapshot，并绑定同版本查询模型；RRF / 业务重排分数均不代表新闻热度或校准后的相关概率。

3 冷温热演练：仅计算分配，三层索引尚未构建

冻结观察日 2026-10-15；热 ⩽ 1 天，温：1 < 天数 ⩽ 4，冷 > 4 天。

日期明确：8,000 篇 / 13,873 片

热层 HOT
1,000 篇 / 1,598 片
10/14 发布

温层 WARM
3,000 篇 / 5,268 片
10/11 至 10/13 发布

冷层 COLD
4,000 篇 / 7,007 片
10/07 至 10/10 发布

日期未知：12,187 篇 / 36,379 片
暂不参与年龄分层，不从正文推测结构化时间

若采用 30 天 / 365 天规则，这 8,000 篇在本次观察日全部为热层。

独立实现：在线生命周期

显式启用配置；BGE 只读快照不能作为写目标

可信入口：新增 / 更正 / 撤稿 / 显式回热
↓
PG 台账：正文、修订号、状态、索引任务
↓
Temporal Worker：切片 → Embedding
↓
Milvus 热 / 温 / 冷集合：写入并完整验证
↓
PG 条件激活 → 清理旧投影 → 查询状态门禁

年龄降层 + 回热保持期；层间量化尚未接入。

依据：v2 build_report.json + chunks.jsonl + 检索 YAML；BgeSnapshotVectorIndex / TieredVectorKnowledgeSearchClient / 生命周期代码。
生成：事实核验 → render_architecture / ReportLab → PDF；校验：单页 + 中文 + 渲染。待做：真实三层索引、迁移与查询实测。