NEWSAGENT / LIFECYCLE + LATENCY / 2026-10-16

三层实施缺口已补齐：迁移可靠，延时可拆解

本轮范围：新闻正文生命周期、检索测时与稳定性；企业参数由你填写，平台性能在目标环境验收。

完整路径：内容事件 → PostgreSQL 台账 → Temporal 任务 → 三层向量 → 状态校验 → 搜索 / 聊天 / 热点

01 写入链路：接受任务与索引就绪是两个状态

内容入口
新增 / 更正 / 撤稿
可信租户 + 单调修订号

→

持久接受
PG 同事务保存正文和任务
冻结策略、模型及重试参数

→

异步处理
派发 → Workflow → Activity
切片 + Embedding 或向量复用

→

验证并激活
目标写入 + 完整校验
generation 条件更新防迟到

→

旧投影清理
清理失败保留错误与任务
单条失败不阻断整页扫描

02 层间迁移：同正文、同模型、同切片时复用向量

热 HOT
age < Th

→

温 WARM
Th ⩽ age < Tc

→

冷 COLD
age ⩾ Tc

复用前核对：修订号、正文、模型身份、维度、切片参数和完整向量清单。
仍需目标写入、验证、激活、删旧；回热走同一迁移链路。

03 查询链路：每层独立计时，并行执行后再次校验

排队 + Query Embedding
总请求预算覆盖排队
503 依赖失败 / 504 超时
失败取消其他等待任务

→

热层　向量搜索 → PG 状态校验 → 过滤 / 有界补搜

温层　向量搜索 → PG 状态校验 → 过滤 / 有界补搜

冷层　向量搜索 → PG 状态校验 → 过滤 / 有界补搜

→

最终状态校验 → 去重融合
输出分层、版本、结果数和 trace
三层并行，耗时不能直接相加
向量 Adapter 耗时含排队与网络

04 你接下来实际执行

填 3 份配置 → Alembic 迁移 → 启动 API 和索引 Worker
投递热 / 温 / 冷新闻 → 等待 ready → 运行 readiness
benchmark_tier_lifecycle.py：固定查询集、并发、预热和超时
查看 samples.jsonl 与 report.json 的 p50 / p95 / p99、错误率

稳定性边界与验收证据

启动检查集合、维度、索引、ef 和必填字段；RPC 有界
超时的同步 SDK 调用完成后才释放额度；扫描按页续跑
本地：真实 PG / Temporal 8 项；回放 35 项；API 冒烟 30 次
企业 Milvus / Embedding、召回质量和规模性能仍需实测

待完成：QA 子文档生命周期、历史归档保留、跨副本全局限流。当前功能未替代这些后续容量与业务工作。

代码：agent/app/knowledge/tier_lifecycle* | 指导：agent/docs/tiered-knowledge-lifecycle.md | 本地替身不代表企业 ANN 性能