三层数据 + 状态 + 迁移：已落地的首版链路

2026-10-15 · Python 原生实现 · 显式启用 · 企业参数由你填写

已验证本地生命周期、真实 PostgreSQL 并发/迁移和 Temporal 派发；企业 Milvus 性能仍需实测。

01 三份配置，各管一件事

模型接口

MODEL_RUNTIME_CONFIG_PATH

模型路由 / 实际维度 / Embedding 批量
企业接口与鉴权环境变量名

向量三集合

KNOWLEDGE_SEARCH_CONFIG_PATH

news_hot / news_warm / news_cold
不同集合；维度、度量与模型一致

生命周期策略

KNOWLEDGE_LIFECYCLE_CONFIG_PATH

Th / Tc / 回热保持期 / 扫描周期
切片上限 / 重试 / 查询候选与总超时

02 分层按业务时间；状态由事件驱动

热 HOT　0 ⩽ age < Th → 温 WARM　Th ⩽ age < Tc → 冷 COLD　age ⩾ Tc

定时扫描降层；显式回热 → HOT；保持期到期 → 按年龄重新分层。

新闻状态

pending → active（API: ready）→ retracted

任务阶段与失败

pending → embedded → active → complete

暂时失败 retry；耗尽 failed；显式重试创建新代次

03 先写目标、验证、切换，再清理源层

内容 API（正文 + 单调修订号） → PG 台账（冻结配置 + 任务） → Temporal（派发 / 重试 / 扫描） → 目标向量层（切片 → 模型 → 验证） → PG 条件激活（校验 generation） → 清理旧投影（独立 ID / 可重扫）

更正：先屏蔽旧版，新版激活再返回。 撤稿：状态先生效，后台删向量。
查询：一次 Embedding → 三层并发 → 状态过滤 / 补搜 → 最终复核 → 去重排序；热点正文同样受控。

验收：后端 3803 通过 / 100 跳过；真实基础设施 7 项通过

本地回放 35 项通过：三层分布、更正、回热、撤稿、乱序、重启恢复

下一步：填配置 → 数据库迁移 → 启动 Worker

先看一条新闻到 ready，再开始真实延时压测。

范围：新闻正文；QA 子文档暂不支持。历史清单归档、企业性能及长稳验收待做。 | 单页图解 1/1