先建立基线，再验证三层、内容变更与延时

从独立 CLI 开始；同一套问题与事件最后接入聊天 / 热点链路，逐步定位差异。

已执行：33项相关测试通过 + 分层决策演示通过 + 真实v2索引24探针ANN基线完成。

后续三层动态测试仍需补实验入口；本页明确标为“待补”，不把方案写成已运行能力。

1 现有回归 — 已跑通 — 版本 / 去重 / 迁移顺序

2 单层基线 — 已跑通 — ANN近邻重合 + p50/p95

3 三层对照 — 待补入口 — 全精度 → 真实压缩

4 变更回放 — 待补入口 — 版本 / 撤稿 / 迁移故障

5 延时矩阵 — 待补入口 — 首次加载 / 并发 / 注入

6 服务验收 — 最后接入 — CLI → API → 聊天/热点

现在就能执行

在仓库根目录运行：

bash output/tiered-recall-test-guide-2026-10-15/run_baseline.sh smoke

smoke：24探针 / K=10 / ef=256；full：96探针 / K=3,10,20 / ef=256,512。

本次单层实测：p50=2.67ms，p95=3.97ms；每次报告使用新路径。

三层实验的输入与对照

仅选有真实日期的8,000篇 / 13,873片，复用原向量行号；日期未知先排除。
观察点10月15日：≤1天热1,000篇，≤4天温3,000篇，其余冷4,000篇。
A单层全精度；B三层全精度；C与B同路由、改真实压缩和加载。
热/温/冷问题均覆盖；向量探针测近邻误差，人工相关标注测语义质量。

内容变化必须逐事件验证：每步都查询、核对台账、记录时间

新增 / 正文更正

新ID可搜；同ID v1→v2
重新嵌入，旧内容不可见

自然降温 / 旧闻回热

可控时钟热→温→冷
合成聚合热度触发晋升

撤稿 / 更新与迁移并发

所有层屏蔽；仅最新版本可见
不因迁移重复加权或漏内容

迁移故障 / 恢复

写入或验证失败保留源层
重试幂等，重启后结果一致

测两类时间 + 一组正确性

查询：编码、每层搜索、加载、融合、完整返回分别计时。
新鲜度：接收变更 → 首次满足预期状态；超时也计为失败。
正确性：Recall@K、旧版本/撤稿残留、重复、丢失、资源占用。

控制变量，逐项扩大

固定模型/查询/seed/K/候选预算/路由；并发按1→4→8增加。
首次进程加载与重复查询分开；不声称清空了操作系统文件缓存。
模拟网络与积压的配置单列；冷层不保证比热层慢。

先补4处：日粒度切层与适配器；FAISS落盘/懒加载修复；版本/撤稿台账；回放器与分层计时报告。

当前ANN报告只测已存文档向量的近邻重合与单线程热缓存耗时，不含BGE编码、HTTP、人工语义质量或三层变更新鲜度。

先看正确性，再比较延时；更多请求再观察尾部，24个探针不能证明稳定的p99或企业容量。

入口：run_baseline.sh → pytest / vector_tier_policy → evaluate_bge_ann → 独立JSON；生成链：回执 → ReportLab → 单页PDF。