NEWSAGENT / READINESS CHECK / 2026-10-15

可以开始测召回延时；动态三层仍需补齐

本轮结论基于相关回归与健康检查。上一轮是实现指导，尚未把设计中的状态与迁移链路接入。

112 项相关测试通过

检索 / 索引 / 模型配置：66 passed
热点运行 / 编排 / SQL绑定 / 对话查询：46 passed

本地 /ready：HTTP 200

PostgreSQL：ok Redis：ok Temporal：ok
健康检查不替代一次新的页面 → Worker → 报告业务验收。

当前可作为延时基线的业务主干

查询入口 — 可信身份 / SQL取数
→ **热点编排** — 指标 / 排名 / 正文
→ **关联召回** — Embedding / 检索
→ **模型与校验** — 结构化输出 / 证据
→ **结果展示** — 保存快照 / API

本地模拟验证已有依据；本轮未发起新业务运行，也未调用企业模型或企业向量服务。

现在做：固定数据的召回延时基线

1 固定数据包、模型、查询集与同一个检索入口
2 分别记录Embedding、向量搜索、融合、端到端耗时
3 同时记录p50/p95、错误率、结果数与召回质量
4 增加并发，观察排队、资源与尾延时

动态三层验收前，还需要实现

持久索引任务与内容事件联动
最新版本 / 撤稿 / 有效层校验
复制 → 验证 → 条件激活 → 清理的可靠迁移
统一查询策略，并补重复、乱序、崩溃恢复回放

下一阶段按这个顺序推进

① 单层固定快照 — 先确定现有耗时与召回基线

② 三层静态查询 — 比较路由 / 并发 / 质量变化

③ 三层动态更新 — 补齐状态链后测新鲜度与恢复

判断边界：主干可进入基线测试 ≠ 企业全链路已验收；三个集合共用资源，也不保证冷热延时天然不同。