向量找关联证据，热点由 SQL / Python 决定

最新本地验收回执：v2 · 20,187 篇新闻 · 50,252 个切片 · BGE 1024 维；本轮未触发部署

关键区分：知识 API 入库与 BGE 快照是两条投影；本地测试 Embedding 不与真实 BGE 向量混用。

A 离线准备：同一份可信缓存，两个输出

1 公开新闻缓存

collect_incremental_news
正文 / 来源 / 发布时间
news_id + 内容版本 + SHA
Manifest 完整性校验

2a 持久入库

import_news_cache → /knowledge/documents → PostgresKnowledgeStore
确定性切片 + EmbeddingPort → PostgreSQL 文档台账与版本化切片

2b 语义索引

build_incremental_news_index → split_text（正文 800 字 / 重叠 80 字）
逐片保留标题/来源/时间 → 本地 BGE 文档编码（无 query 前缀）
1024 维、归一化 float32 → HNSW IP + chunks.jsonl + SHA256SUMS → 新版本原子发布

B 在线召回：BGE 快照当前只启用 HOT 层

3 查询输入

热点：标题 + 摘要
聊天：用户 query
可信租户 / 排除源 ID

4 配套编码器

LocalBgeQueryEmbedder
固定中文 query 前缀
同一 BGE / 1024 维归一化

5 HNSW 搜索

BgeSnapshotVectorIndex
IP 相似度 / 初始池 200
不足则扩池，最多全库

6 新闻去重

先排除源新闻
同 news_id 取最佳片段
校验租户与 Embedding 版本

7 分支消费

显式检索：raw_score 排序
热点 / 自动关联：RRF
输出 RelatedNews / 工具快照

RRF 按排名融合；当前 BGE 单层时为 61 / (60 + rank)。该分数不是原始余弦相似度、相关概率或新闻热度。

热点分析：证据进入模型

HotNewsEnrichmentService.enrich
候选 20 → 正文库补元数据 → 业务重排
40%召回 + 25%主体 + 15%事件
+ 15%关键词 + 5%时间；默认留 3 篇
InputBuilder → 白名单 → 模型 → 校验 / 保存

聊天：两种检索路径

显式 search_knowledge：直接索引召回
各层 raw_score 排序去重，最多 5 篇
自动 related_articles：Tiered client + RRF
最多 3 条源新闻 × 3 篇；每篇 ≤600 字
保存 / SSE；自动卡片不复入聊天模型

配置、依赖与当前边界

KNOWLEDGE_SEARCH_CONFIG_PATH 选择后端
API / Worker 共用 YAML、模型与索引
依赖：SentenceTransformers / NumPy / hnswlib
快照只读；新增数据必须构建并切换新包
时间可展示，检索接口尚无日期过滤参数

核对入口 build_incremental_news_index.py · bge_snapshot.py · tiered_vector.py · conversation/tools.py · hot_news_enrichment.py

验证入口 test_bge_snapshot_index / wiring · test_tiered_vector_retrieval · test_related_news_reranker · test_knowledge_embedding_dimensions

待补：持续增量调度、更正/撤稿执行、生产权限与容量、标注召回质量及运行级版本审计。本轮专项：47 项通过。