01 热点新闻指标

当前热点 SQL 读取字段。每行 = 租户 + 新闻 + 一个小时；所有时间窗口均为左闭右开。

dw.news_behavior_aggregate（视图）

逻辑唯一键：(tenant_id, news_id, event_time)。视图本身没有物理主键。

字段名	SQL 类型	可空	含义 / 当前约束
tenant_id	uuid	否	租户 ID；查询必须限定
news_id	text	否	新闻 ID
event_time	timestamptz	否	统计小时的起点
title	text	否	新闻标题
content_type	text	否	article 图文 / video 视频
category	text	否	新闻栏目
source	text	否	新闻内容来源
publish_time	timestamptz	否	新闻发布时间
impressions	bigint	否	曝光次数，≥ 0
clicks	bigint	否	点击次数，0 到 impressions
unique_users	bigint	否	该新闻、该小时点击去重人数，0 到 clicks
total_duration_seconds	numeric(20,2)	否	累计消费时长，单位秒，≥ 0
effective_consumptions	bigint	否	有效消费次数，0 到 clicks
interactions	bigint	否	互动次数，≥ 0
baseline_impressions	numeric(20,2)	是	同口径历史曝光基线
baseline_clicks	numeric(20,2)	是	同口径历史点击基线
baseline_effective_consumptions	numeric(20,2)	是	同口径历史有效消费基线
baseline_interactions	numeric(20,2)	是	同口径历史互动基线

对应物理表

表名（dw Schema）	主键	保存的字段
dim_news	tenant_id + news_id	新闻 ID、标题、类型、栏目、来源、发布时间
news_metric_hourly	tenant_id + news_id + event_time	6 项行为指标：曝光、点击、UV、时长、有效消费、互动
news_metric_baseline_hourly	tenant_id + news_id + event_time	4 项 baseline_* 基线字段

三张表按主键关联；基线使用 LEFT JOIN，缺失时为 NULL。UV 不能跨小时直接相加；点击 UV 与后文的详情读者人数是不同统计口径。

本文依据当前工作区源码，SQL 使用 PostgreSQL 方言；不包含企业未实现字段。本地行为与读者数据为模拟聚合。

02 新闻正文与内容标签

正文和标签分别存储；发布 ID 与内容哈希用于精确关联同一份内容。未列出的内部审计表不影响本页字段释义。

public.news_content_versions

主键：(tenant_id, news_id, record_sha256)。读取选定内容使用 public.news_content_selected。

字段名	SQL 类型	可空	含义 / 当前约束
tenant_id	varchar(128)	否	内容域租户 ID
news_id	varchar(160)	否	新闻 ID
record_sha256	varchar(64)	否	完整标准化新闻记录的 SHA-256
title	text	是	新闻标题
body	text	是	新闻正文；没有全文时保持 NULL
url	text	是	新闻原始链接
publish_time	timestamptz	是	新闻发布时间
content_type	varchar(16)	否	内容类型，article / video
content_state	varchar(24)	否	body_available / fragments_only / title_only
body_sha256	varchar(64)	是	正文 SHA-256；与整条记录哈希区分
record	jsonb	否	扩展元数据、片段和质量标记

public.news_content_tags

主键：(tenant_id, content_release_id, tag_release_id, news_id)。外键绑定标签发布、正文选定项和内容记录。

字段名	SQL 类型	可空	含义 / 当前约束
tenant_id	varchar(128)	否	内容域租户 ID
content_release_id	varchar(160)	否	正文发布 ID
tag_release_id	varchar(160)	否	标签发布 ID
news_id	varchar(160)	否	新闻 ID
record_sha256	varchar(64)	否	所标注的新闻记录 SHA-256
body_sha256	varchar(64)	是	所标注的正文 SHA-256
label_sha256	varchar(64)	否	标签结果摘要
label_status	varchar(32)	否	tagged / unclassified / insufficient_input / metadata_review
input_scope	varchar(24)	否	title_body / title_only / none
provenance	varchar(32)	否	标签来源标识
topic_ids	jsonb	否	该新闻的主题 ID 数组
label	jsonb	否	完整标签结果，含规则命中与证据

内容标签回答“这条新闻讲什么”。用户兴趣标签回答“这条新闻的读者平时关注什么”，两者不互相替代。

03 用户标签：读者人数与兴趣主题

news_audience 保存新闻受众聚合。短期为 24 小时，长期为 720 小时；一条新闻会分别保存两种兴趣期限。

news_audience.news_reader_population

主键：(tenant_id, snapshot_id, news_id, lookback_hours)。外键：(tenant_id, snapshot_id) → reader_snapshot。

字段名	SQL 类型	可空	含义 / 当前约束
tenant_id	uuid	否	业务租户 ID
snapshot_id	text	否	受众快照 ID
news_id	text	否	新闻 ID
lookback_hours	integer	否	兴趣回看期限：24 / 720
content_sha256	text	是	该新闻的正文 SHA-256
source_has_body_hash	boolean	否	等于 content_sha256 是否非空
reader_count	bigint	否	统计窗口内详情页去重读者数，≥ 0
profiled_reader_count	bigint	否	有已知兴趣的读者数，≤ reader_count
unknown_reader_count	bigint	否	reader_count - profiled_reader_count
cold_start_reader_count	bigint	否	冷启动读者数，≤ unknown_reader_count
baseline_profiled_count	bigint	否	同口径基准有画像人数，≥ 本篇已画像人数
status	text	否	0 人为 empty；大于 0 人为 complete
trigger_article_excluded	boolean	否	必须为 true：兴趣历史排除当前新闻
limitations	text[]	否	限制说明，默认空数组
source_payload_sha256	text	否	源聚合载荷 SHA-256，64 位小写十六进制
source_topic_limit	integer	否	源输出主题数上限，1 到 50
topics_are_top_k	boolean	否	是否只保留部分排名靠前的主题
source_topic_count	integer	否	实际保留主题数，0 到 source_topic_limit

news_audience.news_reader_topic

主键：人群表四列主键 + topic_id。外键关联人群表、同目录快照和 topic_dictionary。

字段名	SQL 类型	可空	含义 / 当前约束
tenant_id	uuid	否	业务租户 ID
snapshot_id	text	否	与人群行一致的快照 ID
news_id	text	否	新闻 ID
lookback_hours	integer	否	与人群行一致的兴趣期限
topic_id	text	否	兴趣主题 ID
topic_reader_count	bigint	否	本篇读者中命中该兴趣的人数，≥ 0
baseline_topic_count	bigint	否	基准人群中命中该兴趣的人数，≥ 本篇人数
taxonomy_version	text	否	主题目录版本
source_rank	integer	否	源主题排名，1 到 50；同组内唯一

主题可以重叠，标签人数不能相加得到 UV；未输出的主题不等于 0 人。导入校验要求标签人数不超过该期限的已画像人数。

04 用户标签：窗口快照与标签目录

每次读取人数和主题，都必须使用同一 tenant_id、snapshot_id 与 taxonomy_version。

news_audience.reader_snapshot

主键：(tenant_id, snapshot_id)。唯一：(tenant_id, source_release_sha256, window_start, window_end)。

字段名	SQL 类型	可空	含义 / 当前约束
tenant_id	uuid	否	业务租户 ID
snapshot_id	text	否	受众快照 ID
window_start	timestamptz	否	本次统计窗口起点
window_end	timestamptz	否	窗口终点；窗口长度大于 0 且不超过 24h
profile_cutoff	timestamptz	否	兴趣特征截止点，必须等于 window_start
knowledge_as_of	timestamptz	否	数据知识截止时间，≥ window_end
knowledge_as_of_basis	text	否	知识截止时间的来源说明
history_start	timestamptz	否	兴趣历史起点，≤ profile_cutoff
source_revision	bigint	否	源修订号，≥ 1
source_release_sha256	text	否	源聚合包 manifest 原始字节的 SHA-256
source_mode	text	否	synthetic / enterprise
taxonomy_version	text	否	主题目录版本
profile_policy_version	text	否	兴趣计算规则版本
identity_policy_version	text	否	读者身份及去重规则版本
reader_definition	text	否	当前固定 detail-view-distinct-v1
count_method	text	否	exact_synthetic_distinct / enterprise_exact_distinct
generated_at	timestamptz	否	快照生成时间，≥ knowledge_as_of
watermark_at	timestamptz	否	已处理数据水位，≤ knowledge_as_of
completeness	text	否	incomplete / complete / corrected
quality_status	text	否	pending / passed / failed
quality_basis	text	否	质量校验依据
expires_at	timestamptz	是	过期时间；enterprise 来源必须提供
min_support	bigint	否	lift 最小样本门槛，默认 5，且 ≥ 5

news_audience.topic_dictionary

主键：(taxonomy_version, topic_id)。父主题外键包含同一 taxonomy_version。

字段名	SQL 类型	可空	含义 / 当前约束
taxonomy_version	text	否	主题目录版本
topic_id	text	否	主题 ID
topic_name	text	否	主题显示名称
parent_topic_id	text	是	父主题 ID；一级主题必须为空
topic_level	smallint	否	一级为 1；下级大于 1 且必须有父主题

快照外键关联 package_release。complete / corrected 要求 watermark_at ≥ window_end。SQL 查询仍需显式过滤 quality_status、completeness 与 expires_at。

05 实时新闻与用户标签同屏查询

news_realtime.news_reader_overview 是当前已定义的查询视图；每行 = 业务租户 + 一分钟窗口 + 新闻。

字段名（可直接 SELECT）	SQL 类型	含义
窗口_北京时间	timestamp	新闻统计分钟起点（北京时间）
新闻标题	text	标题，可空
新闻内容标签	text	主题名以 / 分隔；无标签可为空
详情读者人数	bigint	详情去重读者；尚无画像时为空
近24小时兴趣_TOP3	text	短期兴趣前三项，含占全部读者百分比
近30天兴趣_TOP3	text	长期 720 小时兴趣前三项
窗口状态	text	暂定 / 已定稿
同步检查	text	检查有效 / 检查已过期
曝光次数	bigint	本分钟曝光次数
点击次数	bigint	本分钟点击次数
指标UV	bigint	本分钟点击去重人数
短期已画像人数	bigint	24h 有已知兴趣的读者数；无画像为 NULL
短期未知人数	bigint	24h 未知兴趣读者数；无画像为 NULL
短期冷启动人数	bigint	24h 冷启动读者数；无画像为 NULL
长期已画像人数	bigint	720h 有已知兴趣的读者数；无画像为 NULL
长期未知人数	bigint	720h 未知兴趣读者数；无画像为 NULL
长期冷启动人数	bigint	720h 冷启动读者数；无画像为 NULL
最新事件_北京时间	timestamp	最新已处理事件的发生时间
入库时间_北京时间	timestamp	投影进入 SQL 的时间
检查时间_北京时间	timestamp	最近一次源状态检查时间
数据来源	text	公开新闻缓存 + 模拟读者行为
新闻链接	text	原始 URL，可空
新闻正文	text	全文，可空
完整人群画像_JSON	jsonb	已输出的完整聚合画像；尚无画像时为空
tenant_id	text	业务租户 ID
news_id	text	新闻 ID
window_key	text	分钟窗口唯一身份
window_start	timestamptz	统计窗口起点
window_end	timestamptz	统计窗口终点 = 起点 + 1 分钟
revision	bigint	当前窗口修订号
catalog_id	text	本次内容目录 ID
content_release_id	text	正文发布 ID
tag_release_id	text	标签发布 ID

TOP3 按标签读者数降序、topic_id 打破平局。百分比 = 标签读者数 / 全部详情读者数；兴趣可以重叠。检查有效不代表窗口正好是当前分钟。

完整人群画像_JSON：reader_count 为总人数；short_term / long_term 含 lookback_hours、profiled_reader_count、unknown_reader_count、cold_start_reader_count、baseline_profiled_count、topics。topics 内含 topic_id、reader_count、share_all、share_profiled、baseline_reader_count、baseline_profiled_count、baseline_share、lift、low_sample。

06 直接查询与字段计算

下面 SQL 查询已有对象。第 1 段读取最近已入库窗口；第 2 段查询已导入的固定示例快照，不与实时分钟结果拼接。

1. 查新闻、指标和用户兴趣（统一新闻数据库）

```
SELECT "窗口_北京时间", "新闻标题", "新闻内容标签",
       "曝光次数", "点击次数", "指标UV", "详情读者人数",
       "近24小时兴趣_TOP3", "近30天兴趣_TOP3",
       "窗口状态", "同步检查", "完整人群画像_JSON", news_id
FROM news_realtime.news_reader_overview
WHERE tenant_id = '11111111-1111-4111-8111-111111111111'
  AND window_start = (
    SELECT max(window_start) FROM news_realtime.news_live_current
    WHERE tenant_id = '11111111-1111-4111-8111-111111111111'
  )
ORDER BY "详情读者人数" DESC NULLS LAST, news_id
LIMIT 20;
```

2. 查一篇新闻的短期、长期兴趣及分母（同库 news_audience）

```
SELECT news_id, lookback_hours, topic_id, topic_name,
       topic_reader_count, reader_count, profiled_reader_count,
       share_all, share_profiled, baseline_share, lift, low_sample
FROM news_audience.v_news_reader_topic_metrics
WHERE tenant_id = '11111111-1111-4111-8111-111111111111'::uuid
  AND source_release_sha256 =
      '03fab1518c30f6822aedc73a67bbcede4831273b141db9a4a6aa1c8129ff19f5'
  AND snapshot_id =
      '90d919aee5b20f16d3bc3200e91f65d55120b69458388ba6c883a96d1db4954d'
  AND news_id = '20260718A03B9V00'
  AND completeness IN ('complete', 'corrected')
  AND quality_status = 'passed' AND watermark_at >= window_end
  AND (expires_at IS NULL OR expires_at > CURRENT_TIMESTAMP)
ORDER BY lookback_hours, topic_reader_count DESC, topic_id;
```

已实现的计算字段（news_audience 视图）

字段	计算规则
profile_coverage	已画像读者数 / 全部详情读者数
share_all	标签读者数 / 全部详情读者数
share_profiled	标签读者数 / 已画像读者数
baseline_share	基准标签人数 / 基准已画像人数
low_sample	本篇与基准的已画像人数、标签人数，四项最小值 < min_support
lift	share_profiled / baseline_share；低样本或基准占比为 0 时为 NULL

上述 SQL 比率分母为 0 时返回 NULL。正文关联通过 unified_news_binding 显式映射业务租户与内容域，再同时匹配新闻 ID、正文发布 ID、record_sha256 和 body_sha256。

来源定义：app/sql_assistant/warehouse.py；app/modules/news_storage/{store.py,tag_store.py,realtime_002.sql,realtime_004.sql,realtime_005.sql}；app/modules/reader_profiles/warehouse.sql。路径均相对 agent/。