点击量、访问量：数仓到底怎样算？

核心：记录每次行为 → 消除重复上报 → 按新闻和发生时间分组 → 累加次数、合并去重人群。

企业上游目标链路：工程示意，技术栈待确认

本地 v7：直接生成聚合样本

访问 PV / UV：建议新增口径

工程选项示意：消息流（如 Kafka）、状态计算（如 Flink）、列式 OLAP；它们不属于本地 v7 运行依赖。

上游负责采集、明细、计算与数仓；NewsAgent 只读聚合快照

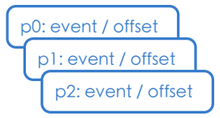
1 客户端埋点



看见 / 点击 / 详情成功
带事件 ID 和原发生时间

发生端

2 接收与缓冲



校验格式、可靠保存
消息重试与按分区回放

接入 / ODS

3 清洗与去重



event_id 去投递重试
view_id 去重复访问上报

清洗 / DWD

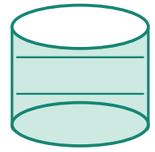
4 分桶与累计



按租户、新闻、渠道
和事件时间维护状态

计算 + 状态

5 聚合快照



5 分钟 / 小时 / 日
修订 / 质量 / 版本

汇总 / DWS

6 指标服务



先取最新修订
再验完整性与质量
不回退旧版

服务 / ADS

7 热点运营



Python 排行与校验
Agent 解释与表达

聚合消费端

窗口计算器：内存里到底存什么？

一条行为包（教学示例）

event_id: e2
event_type: click
news_id: N1 / user_key: A
event_time: 10:02:00
received_at: 10:02:01
channel: recommend
tenant: T1（可信入口映射）

key = 租户 + 新闻 + 渠道 + 小时桶

次数计数器

impression += 1
click += 1
成功访问按 view_id 计数

用户集合 / 去重状态

访问用户：{A, B}
访问 UV = 集合大小
跨桶需合并集合 / 状态

防重 + 恢复状态

已见事件：{e1, e2, ...}
重试丢弃，真二次点击保留
检查点：状态 + 消费进度

精确集合 / Bitmap 或近似 HLL；近似结果需记录方法与误差口径。

写出一行快照（目标合同）

T1 / N1 / recommend
窗口 [10:00, 11:00)
revision: 2 / policy: v1
曝光 4 / 点击 3 / 访问 PV 3
访问 UV 2 / 推荐 CTR 75%

detail_view 与访问字段尚未接入 v7

为什么查询不用每次扫描所有点击？

预聚合把事件变成少量窗口行；按时间分区、新闻与时间键排序 / 索引裁剪扫描。企业可选列存 OLAP；本地模拟使用 PostgreSQL。

重放、迟到和补数怎样不翻倍？

持久去重 + 检查点恢复 + 幂等写出。全量 rev2 替代旧快照，不与 rev1 相加；迟到按原事件时间修订。消息 ACK 本身不保证端到端恰好一次。

13 条上报，怎样算出 PV、UV 和 CTR？

T1 / N1；A、B、C 和所有事件 ID 都是虚构。曝光与归因点击属于推荐场景，详情访问也包括直达。

事件去重：同一 event_id 只算一次

业务去重：同一 view_id 只算一次访问

用户去重：真实多次访问，PV 增加而 UV 不重复

原始上报 → 清洗事实（玩具账本）

事件 ID	行为	人	发生时间	收到时间	view_id	处理说明
e1	曝光	A	10:01:00	10:01:01	-	看见推荐卡片
e2	点击	A	10:02:00	10:02:01	-	第一次点击
e3	详情成功	A	10:02:01	10:02:02	v1	详情页成功打开
e2	点击	A	10:02:00	10:03:00	-	同一次点击重试：丢弃
e4	曝光	A	10:04:00	10:04:01	-	再次看见卡片
e5	点击	A	10:04:01	10:04:02	-	真实第二次点击：保留
e6	详情成功	A	10:04:02	10:04:03	v2	第二次详情访问
e7	曝光	B	10:15:00	10:15:01	-	B 看见卡片
e8	点击	B	10:15:01	10:15:02	-	B 点击
e9	详情成功	B	10:15:02	11:02:00	v3	迟到：仍归 10 点小时
e10	曝光	C	10:32:00	10:32:01	-	C 只曝光，没有访问
e11	详情成功	A	11:01:00	11:01:01	v4	A 直达：没有推荐点击
e12	详情成功	B	10:15:02	11:03:00	v3	新事件 ID，重复 v3：丢弃

13 条上报 → 去掉 e2 重试、重复 v3 → 11 条可计量事实

说明：view_id 的稳定边界由真实埋点合同决定；重复访问上报即使换了 event_id，也不应该创建新访问。真实二次打开必须用新的 view_id。

e9 到得晚，但属于原来的 10 点小时

e9 在 10:15:02 发生，11:02 才收到。未收到时，10 点访问 PV=2、UV=1；在批准迟到策略内修订后变为 3、2。超过策略预算应进补数 / 质量台账。

水位反映事件时间进度；要结合迟到策略、源端覆盖和质量检查。阅读时长应先归并会话和心跳，累计心跳先差分 / 取合法最大值，再判断有效消费。

10 点小时 · 最终修订

曝光 4 / 点击 3 / 访问 PV 3

访问 UV = 2 人：A、B

推荐 CTR = 3 / 4 = 75%

11 点小时 · A 直达访问

点击 0 / 访问 PV 1 / 访问 UV 1

没有推荐曝光，CTR 不可定义；访问量与点击量需要独立埋点、独立统计。

两个小时合并

访问 PV = 4；访问 UV = 2

用户集合 {A,B} ∪ {A} = {A,B}。
2 + 1 不是跨小时 UV；应合并状态再计数。

你的项目当前还缺什么？

v7 没有 detail_view / 独立访问 PV、UV。
旧内存计算器 unique_users 含只曝光的人；
v7 则是合成点击人群，二者还需统一口径。
零曝光 CTR：v7 为 NULL，旧计算器为 0。

[1] Flink：事件时间 / 水位

[2] Flink：检查点

[3] ClickHouse：精确 UV

可选工程依据，不代表腾讯新闻内部实现