本地可以模拟：资源差异 × 查询延时 × 内容演变

已有分层实验和原生检索接口；当前服务仍是单层只读 BGE 快照，需要补接动态实验。

先把数据与实验口径分清

v2：20,187 篇 / 50,252 片 / 1024维；仅8,000篇有结构化日期，另12,187篇日期未知。

热层 HOT

1,000 篇 · 年龄 ≤ 1天

常驻内存 / 全精度 HNSW

新稿、追踪更新；优先快速可见

温层 WARM

3,000 篇 · 1 < 年龄 ≤ 4天

量化索引 / 按需加载

降温、增量修订；记录加载代价

冷层 COLD

4,000 篇 · 年龄 > 4天

紧凑索引 / 磁盘归档演练

历史回溯、旧闻回热；更正仍要及时

以上为演练参数：原始发布时间保留；以10月15日为观察点。原30天/1年规则下，这8,000篇全部在热层。

查询链：用同一问题、同一向量与同一候选预算比较

问题 → BGE向量（单独记录编码时间） → 路由 / 分层预算（全量并发 vs 按需补召回） → 热 / 温 / 冷检索（分层耗时、首次加载、超时） → 有效版本复核（撤稿屏蔽 + 去重 + RRF） → 证据 / 答复（层来源、版本、完整性）

全层并发完整返回约等于：编码 + 最慢层 + 融合；冷层变慢仍会拖住整体。不能只用候选数量决定停止。

变更链：用可控时钟回放，几分钟观察跨天生命周期

新稿 / 更新	自然降温	旧闻回热	历史更正	撤稿 / 迁移失败
热层v1 → 热层v2	热 → 温 → 冷	冷 → 温 → 热	新版本先可见，再归并	全层屏蔽 / 源层保留

台账保存 news_id + 内容版本 + Embedding版本；迁移先写、验证、再删。正文更正不能仅搬移旧向量。

两类延时必须分开量

查询延时：各层 / 完整返回 p50、p95、p99，首次加载与重复查询分开。
变更可见延时：接收新稿或更正 → 能检索；接收撤稿 → 全层不可见。
同时看Recall@K、旧版本命中、重复率、积压、真实索引体积与内存。

本地实测 + 受控故障注入，各自标记

实测：本机搜索、量化、读盘、更新与资源竞争。
注入：网络等待、冷层慢请求、写入积压、迁移中断。
冷索引常驻后也可能很快；注入结果不能当企业集群性能。

实施缺口：日粒度分层适配 + 版本/撤稿台账 + 场景回放 + 分层计时；聊天串行与热点并发两条路径需对齐。

核查：29项相关离线测试通过；FAISS落盘需修复，hnswlib量化账面体积不等于真实内存。变更事件均为合成演练。