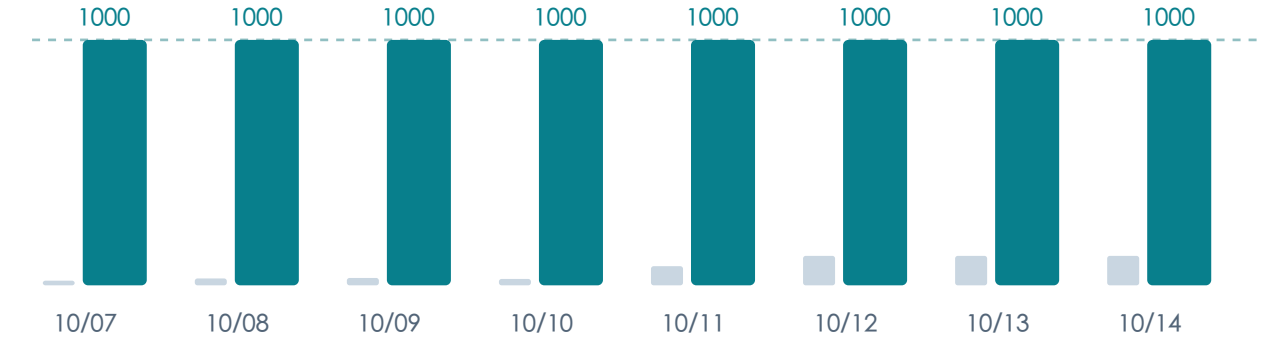
新闻导入扩容：每天千篇，逐篇核验

2026-10-07 至 2026-10-14 · 北京时间 · 完整正文

已采集并入库	每日实际目标	已进入检索索引	逐日缺口
8,000 篇	1,000 篇	8,000 篇	0 篇

每天的完整新闻数量

灰色：上次导入　绿色：扩容后总量



导入数量如何算？

- 以正文 HTML 的发布时间为准
- 按 news_id、标题与正文指纹去重
- 只有可读完整正文才计入成功
- 网址候选数不等于导入数
- 原有 541 篇保留并计入每日总量

完整调用链

公开发现
站点地图 / 原始响应摘要

→

正文校验
清洗、核时间、去重、日配额

→

知识入库
知识 API / PostgreSQL

→

向量与索引
本地 BGE / 1024 维 / HNSW

下游：API + 热点 Worker 加载同一版本 → 聊天与关联新闻检索

核验：数据库内容指纹一致 · 索引全文与元数据一致 · 8 天聊天抽验通过 · 182 项测试通过

边界：有限公开采集，不代表全量档案；真实热度仍需企业聚合指标和基线。

配置：每日目标 1000 / 8 并发 / 有界重试 / 分批检查点 / 新版本索引