01 / NEWSAGENT DATA CONTRACT

热点新闻与用户标签 TDSQL 接入表结构

NewsAgent 技术交接参考 | v1.0 | 2026-10-25（北京时间）

目标：让腾讯新闻内部数仓团队能够按字段、粒度、SQL 与验收条件映射现有数据，支撑“看热点 - 看读者兴趣 - 找关联证据 - 生成人工研判”。本文不要求重建内部数仓。

企业背景由用户确认：内部使用自研实时数仓，TDSQL 体系，以 SQL 查询；此前项目上下文已确认 TDSQL-A / PostgreSQL 兼容方向。内部实例的版本、授权方式、物理表名与指标口径仍需由内部团队提供。

文档标记	含义
现有实现	已对照当前工作区源码、DDL 和配置核实；本次未连接数据库验证部署状态。
建议合同	建议向企业开放的受控 SQL 视图、字段和适配规则；名称为逻辑示例，不是腾讯内部真实表名。
待确认 / 待实现	需要内部表字典、权限、口径或新增适配代码；不能作为已接通企业的证明。

阅读路线

页码	内容	适用人员
02-07	当前表结构、新闻标签、读者聚合及统计口径	应用研发 / 数据分析
08-10	企业 SQL 视图合同、快照元数据、用户画像边界	数仓 / 画像 / 数据平台
11-12	参数化 SQL 查询示例与一致性处理	SQL 接入研发
13-14	Python Port 接线、正文与分层向量召回	Agent / 检索研发
15-16	配置、验收、待办与来源	联调负责人 / 评审

主线：权威数字由 SQL / Python 计算，模型负责解释。企业原始访问明细和逐用户兴趣留在企业侧，NewsAgent 只消费必要的聚合、版本与证据引用。正文内容、检索文本和模型输出均按不可信数据处理。

公开资料只用于核对技术方向：腾讯云 TDSQL-A 产品简介描述了 PostgreSQL 语法兼容及分析能力；这不能证明内部实例与公开产品完全相同。[E1] 本文 SQL 按 PostgreSQL 方言示意，不含生产建表或部署操作。

02 / NEWSAGENT DATA CONTRACT

现有数据对象与职责

同一个 news_id 串联内容、行为、读者兴趣与报告；租户、窗口和版本必须同时对齐。

数据域 / 对象	一行代表什么	用途与边界
dw.dim_news	租户 + 新闻	新闻属性；不是全文版本仓库。
dw.news_metric_hourly	租户 + 新闻 + 小时起点	热点计算的窗口聚合。
dw.news_metric_baseline_hourly	租户 + 新闻 + 小时起点	四项历史基线；缺行经 LEFT JOIN 输出 NULL。
dw.news_behavior_aggregate	上述关联后的同一小时新闻	现有热点 SQL 工具的 18 列读取合同。
news_sim_v8.*	独立扩展模拟数仓	13 表覆盖渠道、5 分钟 / 小时 / 日、修订与生命周期；不等同 dw.*。
public.news_content_*	新闻版本 / 冻结发布 / 标签关系	7 张正文与标签表；来源证据可追溯。
news_audience.*	冻结受众包 / 窗口 / 新闻 / 兴趣期限	7 张聚合表；没有企业个人身份明细。
news_realtime.*	分钟快照、实时预览与最终读者聚合	独立本地流式实验；公开正文 + 合成行为。
analysis_runs	一次租户热点窗口运行	幂等身份、Bundle、处理数量、榜单和分析快照。
hot_events / hot_news_decisions	聚合事件 / 运营决策	应用状态；不是数仓行为事实。

正文、标签、聚合的关联顺序

正文 release 选定 news_id 的内容版本 → 内容标签 release 绑定同一正文版本 → unified_news_binding 按 news_id + 非空 body_sha256 连接业务受众 → reader_snapshot 确定窗口 → population / topic 读取人群与主题。

内容域 public-news-local 使用文本身份，业务受众租户使用 UUID。二者不能直接按 tenant_id 等值连接。企业接入若使用业务线 / app_id，应由可信身份配置完成显式映射。

热点来源：app/sql_assistant/warehouse.py；应用结果：modules/hot_news/persistence/hot_news.py。统一库及实时表的定义见[R2-R5]。以上为代码结构核对，不复述旧文档行数为当前数据库实测。

03 / NEWSAGENT DATA CONTRACT

热点 SQL 合同：18 个核心字段

现有实现 | dw.news_behavior_aggregate；唯一粒度为租户、新闻、一个完整小时。

字段	类型 / 空值	定义与企业映射要求
tenant_id	uuid / 必填	可信业务隔离域；所有筛选、关联、缓存均带此字段。
news_id	text / 必填	稳定新闻 ID；与正文、标签及索引采用同一身份。
event_time	timestamptz / 必填	小时起点；区间为 [start, end)，不是事件入库时间。
title	text / 必填	新闻标题；来自批准的内容维度。
content_type	text / 必填	article / video；企业实际类型需映射。
category	text / 必填	新闻栏目；不是用户兴趣，也不是访问渠道。
source	text / 必填	内容来源展示标记；不是推荐、搜索等流量入口。
publish_time	timestamptz / 必填	真实发布时间；不得使用接入时间代替。
impressions	bigint / 必填	有效曝光事件次数；去重、可见性口径由企业定义。
clicks	bigint / 必填	点击事件次数；归因规则与曝光计数须对齐。
unique_users	bigint / 必填	目标新闻、目标小时的点击 UV；不是详情读者数。
total_duration_seconds	numeric(20,2) / 必填	累计消费秒数；现有领域对象要求整数秒，见第 13 页。
effective_consumptions	bigint / 必填	有效阅读 / 播放次数；当前模拟为点击归因口径。
interactions	bigint / 必填	批准的互动事件总次数，不是互动 UV。
baseline_impressions	numeric(20,2) / 可空	曝光历史基线；无样本输出 NULL。
baseline_clicks	numeric(20,2) / 可空	同口径点击基线；零基线与无基线区分。
baseline_effective_consumptions	numeric(20,2) / 可空	有效消费基线；不得引入目标窗口后的样本。
baseline_interactions	numeric(20,2) / 可空	互动基线；使用同单位和口径。

物理主键：dim_news 为 (tenant_id, news_id)；指标、基线为 (tenant_id, news_id, event_time)。基线物理列非空，但无基线可以不插入该行，视图 LEFT JOIN 后为空。[R1]

热点默认分数 = 0.30×点击率 + 0.35×有效消费率 + 0.20×互动分量 + 0.15×压缩增长分量；比例被限定在 [0,1]，增长仅奖励正增长。实际运行须绑定批准规则版本；这不是企业已有热榜的原始分数。[R6]

04 / NEWSAGENT DATA CONTRACT

统一正文与新闻内容标签

现有实现 | public Schema 的 7 张表；标签描述新闻内容，不描述读者。

对象 / 主键	主要字段与用途
news_content_versions PK: tenant_id, news_id, record_sha256	title、body、url、publish_time、content_type、content_state、body_sha256、record(JSONB)。record_sha256 是整条标准化记录摘要；body_sha256 仅为正文摘要。
news_content_releases PK: tenant_id, release_id	identity_sha256、schema_version、selection_policy、status、manifest(JSONB)、created_at。冻结选择结果，不隐式取 latest。
news_content_release_items PK: tenant_id, release_id, news_id	record_sha256、quality_flags(JSONB)。每个 release 为每篇新闻选定一个内容版本。
news_content_provenance PK: tenant_id, release_id, news_id, record_sha256, source_sha256	source(JSONB) 保存来源包、路径、原文件哈希、采集时点和选择优先级等证据。
news_content_tag_releases PK: tenant_id, content_release_id, tag_release_id	content_identity_sha256、identity_sha256、schema_version、derivation_version、policy_version、taxonomy_version、tagger_sha256、status、manifest、policy、created_at。
news_content_tags PK: tenant_id, content_release_id, tag_release_id, news_id	record_sha256、body_sha256、label_sha256、label_status、input_scope、provenance、topic_ids(JSONB)、label(JSONB)。label 保留规则命中及证据位置。
news_content_topic_memberships PK: 上述标签主键 + topic_id	将一篇新闻的多个主题拆成关系行；主题过滤发生在分页之前，包含继承父主题。

企业映射

建议企业提供稳定 news_id、内容版本 / 哈希、正式栏目、状态和正文对象引用；正文仍由内容服务或对象存储读取。NewsAgent 本地公开正文目前在 PostgreSQL，不能据此要求内部把全文搬进实时数仓。

label_status：tagged / unclassified / insufficient_input / metadata_review。现有 12 个一级主题、72 个二级主题为本地草案；生产须绑定企业批准目录。规则推断标签、企业栏目、人工金标必须分别标识。

查询视图：news_content_selected 与 news_content_tagged_selected。类型细节与完整说明见 [R2]；实现见 modules/news_storage/store.py、tag_store.py。

05 / NEWSAGENT DATA CONTRACT

受众表：来源、绑定与窗口

现有实现 | news_audience；这一页固定“这批人群数字来自哪里、对应哪篇正文”。

对象 / 粒度	字段组与约束
package_release PK: source_release_sha256	manifest、policy、schema_version、row_counts、projection_digests、imported_at。来源身份为 manifest 原始字节 SHA-256，导入后按摘要核对投影。
content_binding PK: tenant_id, source_release_sha256, news_id	content_sha256（可空）、content_topic_ids、binding。表示源包有这篇新闻；不能据此认定统一正文已匹配。
unified_news_binding PK: 上述三字段 + content_tenant_id, content_release_id	record_sha256、body_sha256、binding_method、bound_at。按 news_id + 非空正文哈希精确映射，禁止按相似标题猜测。
reader_snapshot PK: tenant_id, snapshot_id	window_start/end、profile_cutoff、knowledge_as_of、knowledge_as_of_basis、history_start；窗口与特征截止时点分开。
reader_snapshot / 来源与版本	source_revision、source_release_sha256、source_mode、taxonomy_version、profile_policy_version、identity_policy_version、reader_definition、count_method。
reader_snapshot / 质量与时效	generated_at、watermark_at、completeness、quality_status、quality_basis、expires_at、min_support。唯一约束另包含 tenant + release + window。
topic_dictionary PK: taxonomy_version, topic_id	topic_name、parent_topic_id、topic_level。父主题外键包含同一 taxonomy_version。

固定范围与时间语义

当前冻结受众导入表将一个来源 release 的同一租户、同一窗口限定为一份覆盖快照。它不能直接承担无限实时修订追加；企业实时接口建议采用第 8-9 页的独立快照合同，而不是原地修改冻结表的含义。

profile_cutoff = window_start，历史特征不得越过它。knowledge_as_of 是本地包冻结时点；不能冒充企业事件实际到达的历史时点。源内容绑定和窗口覆盖共同成立，才能解释缺失人群行。

企业读者人数全部由上游在批准身份域内去重。NewsAgent 不接收 user_id、设备 Token 或原始浏览日志。个人行为目前仅存在隔离的合成实验中。[R3]

06 / NEWSAGENT DATA CONTRACT

受众表：人数与兴趣主题

现有实现 | 人数表存分母，主题表存分子；关联必须包括租户、快照、新闻和兴趣期限。

news_reader_population 字段	类型	说明
tenant_id / snapshot_id / news_id	uuid / text / text	新闻窗口身份；构成复合主键前三项。
lookback_hours	integer	主键第四项；当前表只允许 24 / 720。
content_sha256 / source_has_body_hash	text? / boolean	正文绑定；保留源哈希是否确实存在。
reader_count	bigint	该窗口进入新闻详情页的去重读者数。
profiled_reader_count	bigint	该兴趣期限内具有可用画像的人数。
unknown_reader_count / cold_start_reader_count	bigint / bigint	未知 = 总读者 - 有画像；冷启动是未知的子集。
baseline_profiled_count	bigint	同口径基准人群中有画像人数。
status / trigger_article_excluded	text / boolean	complete 或 empty；排除触发新闻自身历史贡献。
limitations / source_payload_sha256	text[] / text	历史不足等限制；原聚合载荷摘要。
source_topic_limit / topics_are_top_k / source_topic_count	integer / boolean / integer	源 Top-K 上限、是否截断型输出、实际主题条数。

news_reader_topic 字段	类型	说明
tenant_id / snapshot_id / news_id / lookback_hours / topic_id	复合主键	一篇新闻、一个兴趣期限、一个保留主题。
topic_reader_count	bigint	读者中命中该主题的人数。
baseline_topic_count	bigint	基准人群中命中该主题的人数。
taxonomy_version	text	连接版本化字典与快照。
source_rank	integer	保留上游主题排名；同一人群内唯一。

索引覆盖按新闻查快照、按主题人数排序、按主题筛新闻。SQL 视图 v_news_reader_population_status 返回画像覆盖率；v_news_reader_topic_metrics 返回占比、基准、lift 和低样本标记。[R3]

当前精确计数合同要求主题人数不超过画像分母，读者群包含于其基准群；这些跨表条件部分由导入和 Python 校验承担，不应误称全部已由数据库 CHECK 保证。

07 / NEWSAGENT DATA CONTRACT

用户标签与统计口径

同一新闻可以有多个内容主题，同一个读者也可以属于多个兴趣主题。

指标 / 规则	确定定义	接入约束
详情读者 reader_count	在 [window_start, window_end) 内有 detail_view 的 distinct 身份数	点击 UV、曝光 UV、详情 PV 都不能替代它。
短期 / 长期兴趣	[start-24h, start) / [start-720h, start)	分别计算；不是把小时读者数或每日画像直接求和。
访问前画像	profile_cutoff 不晚于目标窗口起点	窗口内新行为不能倒灌解释本次受众。
触发新闻排除	移除目标 news_id 的全部历史贡献	包括历史点击、阅读、互动和负反馈。现成用户标签未必支持。
share_all	topic_reader_count / reader_count	占全部详情读者比例。
share_profiled	topic_reader_count / profiled_reader_count	占有画像读者比例；分母可能小于总读者。
baseline_share	baseline_topic_count / baseline_profiled_count	基准范围、同样的期限及目标新闻排除规则必须明确。
lift	share_profiled / baseline_share	低样本或基准为零时不输出；不是因果效果。
低样本	现有策略对两个人群分母和两个主题分子取最小值，低于 5 则抑制 lift	企业阈值改变必须另设策略版本。
Top-K / 父子主题	主题可重叠；未返回的主题不代表零	不能把主题人数求和得到总人数。

缺失、零值与精度

仅当新闻在来源范围内，目标窗口完整且有明确覆盖，才能将“没有详情访客”输出为 empty / 0。未绑定新闻、未覆盖窗口、失败或过期应返回 unavailable / 错误，不能补零。

SQL 用 NULLIF 保留零分母为 NULL；现有 Reader DTO 的比例字段使用八位 HALF_EVEN 且零分母返回 0。Adapter 须明确执行该既有边界转换并保留 empty 状态，不能把 SQL NULL 误当原始计数缺失。

当前 Reader DTO 允许带 error_bound 的近似人数，但 news_audience 冻结 SQL 表仅接受 exact 计数，严格精度校验也未证明兼容任意近似算法。建议首版企业接入用精确聚合；近似计数另立版本并验收。[R3-R4]

08 / NEWSAGENT DATA CONTRACT

建议开放的企业 SQL 视图

建议合同 | na_contract 是本文示例 Schema。企业可以用已有表的受控视图或 SQL 网关提供相同语义。

建议视图 / 唯一粒度	返回内容	对应现有能力
snapshot_v1 tenant + domain + snapshot_id	窗口、修订、水位、完整性、质量、来源与版本；domain = metrics / readers	补齐现有 18 列视图缺失的快照元数据。
news_metric_v1 tenant + snapshot_id + news_id	第 3 页 18 列 + content_version、content_sha256、baseline_version、baseline_sample_count	映射 NewsMetricSnapshot / 基线；当前指标视图无 snapshot_id。
news_content_ref_v1 tenant + news_id + content_version	title、content_type、category、publish_time、content_sha256、content_status、lifecycle_revision、status_effective_at、body_ref、source_url?	映射 NewsContentRepository；正文通过 body_ref 解析。
news_content_tag_status_v1 tenant + news_id + content_version + tag_version	taxonomy_version、tag_status、label_origin、content_sha256	即使没有主题，也明确记录未分类或输入不足。
news_content_topic_v1 标签状态键 + topic_id	taxonomy_version、confidence?、evidence_ref?	映射内容主题；外键指向同版本标签状态。
topic_dictionary_v1 tenant + taxonomy_version + topic_id	topic_name、parent_topic_id?、topic_level、status	企业批准 TopicCatalog；需显式授权共享目录。
news_reader_population_v1 tenant + snapshot_id + news_id + lookback_hours	第 6 页人口字段；来源版本通过 snapshot 关联	ReaderProfileSummary 的人数和长期 / 短期分母。
news_reader_topic_v1 人口键 + topic_id	topic_reader_count、baseline_topic_count、taxonomy_version、source_rank	ReaderTopic；分子和分母分开返回。

类型约定：外部身份和版本使用受限字符串；计数为 bigint；比例采用 decimal；时间使用带时区时间戳；哈希为 64 位十六进制字符串。tenant 到当前 UUID 的映射只由服务身份配置完成。问号表示可空。逻辑视图不强制企业采用 JSONB、触发器或同样物理表。

发布协议

一次发布先完整生成同一 snapshot_id 下的数据，再原子发布快照清单。清单的“已发布”状态与业务质量状态分开；最新已发布修订即使质量不合格也不能悄悄回退旧版。每个 snapshot 的事实行不可原地修改。

指标与画像可有不同 snapshot_id，运行记录二者；必须同租户、同窗口、内容绑定一致，并各自通过完整性门禁。跨系统若无一致快照令牌，需要冻结结果与版本引用后再分析。

09 / NEWSAGENT DATA CONTRACT

建议合同：快照与版本元数据

建议合同 | 在现有核心业务字段之外补齐；不能只增加一个 revision 就声称获得一致快照。

snapshot_v1 字段组	类型 / 必填条件	语义
tenant_id / domain / snapshot_id	text / 必填	逻辑主键；domain 限 metrics / readers。
window_start / window_end	timestamptz / 必填	准确目标区间；同一窗口各修订为替代关系。
source_revision / schema_version	bigint / text / 必填	窗口内单调修订；结构合同版本。
publication_status / completeness	text / 必填	发布标志 published；完整性 incomplete / complete / corrected。
quality_status / quality_basis	text / 必填	passed / pending / failed 及判定规则版本或引用。
watermark_at / generated_at	timestamptz / 必填	处理水位与结果生成时间；完整窗口至少 watermark ≥ end。
expires_at	timestamptz / 企业在线必填	结果时效；过期不冒充当前可用。
source_release_sha256 / data_origin	text / 必填	不可变来源发布身份；enterprise_measured / synthetic 等枚举。
metric_definition_version / uv_method	text / metrics 必填	指标、身份去重方法版本；不以本地模拟算法代替企业口径。
taxonomy_version / profile_policy_version	text / readers 必填	批准的目录与兴趣策略。
identity_policy_version / count_method	text / readers 必填	身份合并规则；首版 enterprise_exact_distinct。
profile_cutoff / history_start	timestamptz / readers 必填	特征可见边界与实际可用历史；不足 720h 必须标记。
knowledge_as_of / evidence_ref	时间 / 引用 / 必填	实际数据可见时点和受控快照证据；不能以本地时间猜测。
content_snapshot_ref / expected_row_count	text / bigint / 必填	关联内容版本集；校验域内主事实行数。readers 指人口行数。
result_digest	text / 建议必填	按约定顺序与规范化规则计算的结果摘要。

查询回执另保存 query_id、elapsed_ms、truncated、实际返回行数和快照引用；query_id 是执行追踪号，不是快照或业务幂等键。网关没有原生快照令牌时，应证明一次受控一致性读取覆盖候选、补充指标和基线。

实时来源 release 轮换是接入缺口：当前 Reader 工厂静态绑定一个 SHA。生产滚动发布需要明确不可变 release 的覆盖范围及受控切换机制；不能随意用查询时间或 snapshot_id 代替来源发布身份。

10 / NEWSAGENT DATA CONTRACT

企业侧用户标签如何形成聚合

建议合同 | 可以映射企业已有画像平台；不要求 NewsAgent 自建推荐算法或拉取个人行为。

仅在企业侧的逻辑数据	建议关键字段	使用约束
用户画像覆盖快照 一用户、一特征截止、一策略	tenant_id、user_key、profile_cutoff、profile_version、known、cold_start、history_start、generated_at	user_key 由企业身份系统管理；未命中主题不等于没有画像。
用户 - 兴趣主题关系 覆盖快照 + 期限 + topic	user_key、lookback_hours、taxonomy_version、topic_id、interest_score、member_flag、profile_policy_version	保留得分与成员阈值含义；标签多值；不能直接把概率当人数。
新闻详情访客集合 租户、新闻、目标窗口、用户	tenant_id、news_id、window_start/end、user_key、identity_policy_version、content_version	企业内做去重集合；不传出个人列表。
按目标新闻校正的画像 / 聚合	target_news_id、profile_cutoff、lookback_hours、trigger_article_excluded、policy_version	必须移除目标新闻历史贡献；仅有一份通用用户标签快照通常做不到。

企业内计算顺序

1. 固定租户、新闻、窗口、内容版本和画像截止时点；对详情访客做 distinct。
2. 获取截止时点前的长短期画像，并对目标新闻执行贡献排除。
3. 按同一身份、期限、策略生成可比基准群；该群须包含目标读者群。
4. 计算读者分母、主题人数、未知 / 冷启动、基准分母及基准主题人数。
5. 先完成全量主题统计再按约定 Top-K 截断，保留源排名与限制。
6. 原子发布人口表、主题表和快照清单；NewsAgent 只查询聚合视图。

若内部已有标签不能排除目标新闻：应明确“无法满足当前策略”，新增经审核的策略与解释方式后再接入，不能把 trigger_article_excluded 填 true。企业实际兴趣算法也不必照搬本地 3 天半衰期和 0.2 阈值。

可选推送受众预估属于另一条聚合合同：主题交并集、排除主题、通知资格、频控和去重覆盖由企业服务计算。读者兴趣表不含接收名单或设备 Token，也不能代替可推送人数；正式推送仍需审批与投递系统。[R7]

11 / NEWSAGENT DATA CONTRACT

SQL 示例：冻结快照后取热点

建议模板 | 仅供受控 Adapter / 数仓视图开发；不是允许模型任意执行的 SQL。

先在批准的一致性读取内查最新已发布修订，再由 Python 判完整性、质量和时效。下面不在选最新前过滤 passed，避免最新坏快照被旧好快照掩盖。命名参数交给驱动绑定。

```
SELECT snapshot_id, source_revision, completeness,
       quality_status, watermark_at, generated_at,
       expires_at, source_release_sha256,
       metric_definition_version, content_snapshot_ref
FROM na_contract.snapshot_v1
WHERE tenant_id = :tenant_id AND domain = 'metrics'
  AND window_start = :window_start
  AND window_end = :window_end
  AND publication_status = 'published'
ORDER BY source_revision DESC
LIMIT 1;
```

门禁通过后，固定返回的 :metric_snapshot_id。第一阶段沿用现有完整单小时；分钟或跨小时需要新合同，不能简单 SUM 小时 UV。

```
SELECT news_id, event_time, title, content_type,
       category, source, publish_time,
       impressions, clicks, unique_users,
       total_duration_seconds, effective_consumptions,
       interactions, baseline_impressions, baseline_clicks,
       baseline_effective_consumptions, baseline_interactions,
       content_version, content_sha256,
       baseline_version, baseline_sample_count
FROM na_contract.news_metric_v1
WHERE tenant_id = :tenant_id
  AND snapshot_id = :metric_snapshot_id
  AND event_time = :window_start
ORDER BY clicks DESC, news_id ASC
LIMIT :candidate_limit;
```

这里按点击取候选，最终热度由 Python 计算。即使随后计算热度，也只是该候选范围内的排名；要称“全域热度 TopN”，必须证明候选覆盖完整或另行批准候选策略。内容权限与有效状态在受控视图及正文读取时再次核验。

参数 / 回执	约束
tenant_id / 窗口 / snapshot_id	来自可信身份、获准业务窗口与服务端查回结果；不接受模型自行指定租户。
candidate_limit / timeout / truncated	设置有界候选、SQL deadline；意外截断或重复主键应失败，不伪装完整结果。
结构与执行计划	逐实例验证类型、参数、事务隔离、扫描范围；公共文档的兼容性不能代替内部验收。

12 / NEWSAGENT DATA CONTRACT

SQL 示例：读者兴趣聚合

建议模板 | :reader_snapshot_id 按第 11 页同样方法从 readers 域选择并完成门禁。

示例查单篇新闻的两个期限。返回粒度为一个期限的一个主题，人口分母会重复显示，不能在结果集上 SUM 人数。多篇使用驱动绑定的 ID 集合，每批不超过现有 Port 的 20 篇。

```
SELECT p.news_id, p.lookback_hours, p.reader_count,
       p.profiled_reader_count, p.unknown_reader_count,
       p.cold_start_reader_count, p.baseline_profiled_count,
       p.status, p.content_sha256, p.trigger_article_excluded,
       p.source_topic_limit, p.topics_are_top_k,
       p.source_topic_count, t.topic_id, d.topic_name,
       t.topic_reader_count, t.baseline_topic_count,
       t.source_rank,
       t.topic_reader_count::numeric
         / NULLIF(p.reader_count, 0) AS share_all,
       t.topic_reader_count::numeric
         / NULLIF(p.profiled_reader_count, 0) AS share_profiled,
       t.baseline_topic_count::numeric
         / NULLIF(p.baseline_profiled_count, 0) AS baseline_share
FROM na_contract.news_reader_population_v1 p
LEFT JOIN na_contract.news_reader_topic_v1 t
  ON t.tenant_id = p.tenant_id
 AND t.snapshot_id = p.snapshot_id AND t.news_id = p.news_id
 AND t.lookback_hours = p.lookback_hours
LEFT JOIN na_contract.topic_dictionary_v1 d
  ON d.tenant_id = t.tenant_id
 AND d.taxonomy_version = t.taxonomy_version
 AND d.topic_id = t.topic_id
WHERE p.tenant_id = :tenant_id
  AND p.snapshot_id = :reader_snapshot_id
  AND p.news_id = :news_id
  AND p.lookback_hours IN (24, 720)
ORDER BY p.lookback_hours, t.source_rank;
```

用 LEFT JOIN 保留零主题的人口行。Adapter 核对两个期限、主题唯一性、目录一致性、分子分母关系，并按第 7 页计算八位比例与 lift。不存在人口行时先核实新闻资格和覆盖；未经证明不能制造 empty。

关联校验：读者快照与指标快照须同租户、同窗口；读者 content_sha256 与所用正文一致。正文或目录更新不得被缓存遮蔽。多次 SELECT 要共享可重读的快照 / 令牌；无法保证时拒绝形成完整分析。

实时预览与最终快照分开：进行中窗口只能标 provisional。当前 ReaderProfileService 要求 is_complete，预览不能直接送入最终分析。窗口关闭还须满足迟到预算、源覆盖与质量条件。

13 / NEWSAGENT DATA CONTRACT

接入现有 Python 调用链

现有能力可复用；新增 SQL 适配层需要实现和验收。本次 PDF 不修改运行代码。

阶段	现有入口 / 核心类	企业对接工作
触发与规划	/chat 或热点 API → 受限意图 → compile_query / Guard → Temporal	服务端固定租户与批准视图；新合同另建版本，不改冻结 v1/v7。
数仓执行	SqlWarehouseClient.execute(SqlQuery) → SqlQueryResult	新增真实 TDSQL SQL 网关 / 协议 Adapter；只执行已校验模板。
指标和热度	NewsMetricSnapshot → HotScoreCalculator → HotNewsRanker	保留整数 / Decimal、单位、基线口径；不让 LLM 填权威数值。
正文	NewsContentRepository → HotNewsEnrichmentService	通过 news_id + 内容版本 / 哈希解析正文对象，校验权限和撤稿。
读者画像	NewsReaderProfilePort → ReaderProfileService → ReaderProfileBatch	建议新增 SqlNewsReaderProfileClient；现有工厂仅 local_package / enterprise_http。
证据与解释	KnowledgeSearchClient → RelatedNewsReranker → NativeHotNewsAnalysisRunner → Validator	只将通过校验的正文、关联证据和聚合画像送入模型。
输出	analysis_runs / Artifact → API、SSE、运营页面	保存双快照、版本、SQL 哈希、query_id 与受控证据引用。

需要补齐的真实差异

① 现有 SqlQueryResult 仅有 rows / elapsed_ms / truncated，没有快照或 query_id。建议在 Adapter 的运行回执中补充版本化审计结构，不把新字段强塞入严格业务 Schema。
② 数据库时长支持小数秒，部分领域对象要求整数秒。必须批准精度策略后同步 Schema 和测试，不能隐式 int() 截断。
③ 现有基线补充路径的 sample_count 可能只是模拟占位，企业必须返回真实样本数。
④ Reader 静态 release、企业目录批准状态、画像策略和 Prompt 白名单须共同冻结；滚动版本解析尚需实现。

资料说明了接口所需语义；真实企业 SQL 查询、权限、TDSQL 兼容性与负载验收仍未完成。内部已有 HTTP 聚合服务时可复用现有 enterprise_http；若要求直接 SQL，则实施上面的新 Adapter，不另起第二套热点业务流程。

主要源码：clients/enterprise/sql_warehouse.py、modules/reader_profiles/contracts.py / service.py / factory.py、modules/hot_news/analysis/hot_news_enrichment.py。[R4、R6]

14 / NEWSAGENT DATA CONTRACT

与分层向量召回的连接

分层索引用于找证据；它不生成新闻热度，也不存企业个人兴趣向量。

对象	关键字段 / 配置	职责
tier_lifecycle_news	tenant_id、news_id、source_revision、generation、status、content_hash、desired_tier、active_tier、active_job_id、config	正文和有效投影台账；决定查询可见性。
tier_lifecycle_jobs	job_id、news_id、generation、target_tier、payload、records、chunk_ids、phase、status、cleanup_dirty	可恢复任务与完整向量快照。
Milvus 三集合 hot / warm / cold	chunk_id、tenant_id、news_id、content_version、chunk_index、embedding_version、title、excerpt、source_url、publish_time_epoch、vector	可重建的检索投影；每层集合独立，模型版本和维度一致。
tier_lifecycle_vectors	chunk_id、tenant_id、tier、record	仅本地持久 SQL 向量替身，不是企业 ANN 性能证明。

入库与查询

内容源 → 栏目准入 / 文本质量校验 → KnowledgeLifecycleService.accept → PG 任务 → Temporal Worker → split_text → EmbeddingPort → 写入并验证目标层 → 条件激活 → 清理旧层。
查询 → Query Embedding → 三层并发 → GuardedTieredIndex 有效状态过滤 / 有界补搜 → 最终校验 → 新闻去重和加权排名融合 → RelatedNewsReranker → 证据白名单。[R8]

策略项	当前实现 / 边界
分层与回热	按新闻年龄和显式回热保持期；秒级本地阈值只用于演示。访问热度自动升层、不同量化精度主要在实验目录。
更正 / 撤稿 / 迁移	更正先挡旧版；撤稿先改查询状态再删除；迁移验证目标后切换，纯迁移可校验后复用向量。
标签如何参与	内容主题可用于筛选或批准的重排；可选本地合成兴趣加分有上限，不改变权威热度。读者聚合主要进入受众分析。
当前接线区别	BGE 冻结快照为单 HOT 路由；实时实验为 SQL 词面召回。统一正文 release 尚未自动同步生命周期索引。

健康栏目按明确来源 category 排除，不能按正文词语或推断 health 主题误删。企业正文在对象存储时，要建立内容版本、事件修订和台账映射；不能把任意字符串 content_version 直接强转生命周期的单调整数修订。

15 / NEWSAGENT DATA CONTRACT

配置与企业验收清单

以下是对接验收项目，不是本次已执行的测试结果；吞吐与延迟目标由内部约定。

验收项	必须可重复验证的结果
字段映射与类型	每个必需字段有源表 / 表达式 / 单位 / 空值 / 负责人；整型、Decimal、时区及新闻 ID 无损。
窗口与修订	迟到、补数、最新坏快照、读取中修订均可复现；不混版、不回退、不重复计数。
UV 和读者	点击 UV 与详情 UV 分开；跨小时目标 UV 独立重算；主题重叠不相加。
画像因果边界	窗口内未来行为与目标新闻历史贡献不影响当前画像；基准群与读者群使用同策略。
空 / 缺失 / Top-K	覆盖内零读者、未覆盖、失效、未知画像、少主题与截断分别正确表达。
内容和权限	租户隔离、内容哈希错配、撤稿、受限新闻、目录错版均被拦截。
SQL 与资源	参数绑定、白名单、只读角色、超时、取消、结果行数和字节数上限；异常不能伪装空结果。
可追踪与回放	每轮查询 / 快照 / Workflow / 模型调用可关联；汇总值、哈希和审计引用足以复现。
规模和持续更新	按实际分区、分布键、并发、修订频率压测 P50/P95/P99、扫描量和数据新鲜度；不外推本地样本。

配置入口与当前默认

热点：HOT_NEWS_DEPENDENCIES_FACTORY；模型：MODEL_RUNTIME_CONFIG_PATH。
画像：READER_PROFILE_ENABLED、BACKEND、TAXONOMY_PATH、SOURCE_RELEASE_SHA256、POLICY_VERSION、ALLOWED_ANALYSIS_PROMPT_VERSIONS；默认单次 3s、全轮 5s、缓存 30s、并发 16、响应 512 KiB。以上变量均带 READER_PROFILE_ 前缀。
检索：KNOWLEDGE_SEARCH_CONFIG_PATH、KNOWLEDGE_LIFECYCLE_CONFIG_PATH。企业 SQL DSN / 网关地址、证书、角色与超时配置由新增 Adapter 定义，当前没有已完成的 TDSQL 配置开关。

只读权限参考腾讯云官方说明 [E2]；实际内部角色、允许 Schema / 视图及租户访问控制以内部授权为准。建议按时间范围裁剪扫描，在企业内预聚合读者主题，评估分布键是否支持同域关联；不在未知内核上预写分布式 DDL。

现有回归入口：test_sql_assistant_warehouse.py、test_reader_profile_contracts.py、test_reader_profile_client_service.py、test_reader_profile_warehouse.py、test_tier_lifecycle_runtime.py、test_tiered_vector_retrieval.py。新增 SQL Adapter 仍需真实隔离企业环境的合同测试。[R9]

16 / NEWSAGENT DATA CONTRACT

交接信息、待办与来源

本次交付为 PDF 设计参考；没有执行企业 SQL、变更数据库、启用 Worker 或修改生产配置。

交接项	完成接入所需内容
内部团队提供	内核 / 协议 / 网关合同；正式表字典与样例聚合；新闻与业务域映射；指标定义；批准主题目录；窗口关闭 / 修订 / 快照协议；只读权限与预算。
项目需要实现	TDSQL SqlWarehouseClient；直接 SQL Reader Port 及工厂注册；滚动 release 绑定；查询回执；时长精度与真实基线样本映射。
共同验证	本文第 15 页验收矩阵；字段源表达式逐项签认；正文对象读取与撤稿 / 限权；规模与长稳；画像质量和运营使用效果。

本次文件生成与验证调用链

上游：当前仓库 DDL / Port / 服务实现、项目背景、用户确认及两份官方资料。
转换：生成脚本内的页级字段表、SQL 模板与说明 → ReportLab（内嵌中文字体）→ 本 PDF。
验证：pypdf 提取文字与页数 / 必需关键词检查 → Poppler 渲染所有页面 → 人工式逐页视觉核对。
配置：PDF_CJK_REGULAR、PDF_CJK_BOLD 可覆盖字体路径；仅用于文档生成，不读取 .env。
下游：可供内部字段映射和评审；未完成事项见上表。

仓库依据（以当前工作区源码为准）

[R1] agent/app/sql_assistant/warehouse.py；agent/docs/enterprise-tdsql-warehouse-contract.md

[R2] agent/app/modules/news_storage/store.py、tag_store.py；agent/docs/news-storage-database-reference.md

[R3] agent/app/modules/reader_profiles/warehouse.sql、build.py、warehouse.py

[R4] agent/app/modules/reader_profiles/contracts.py、service.py、factory.py

[R5] agent/app/modules/news_storage/realtime.sql、realtime_002.sql 至 realtime_005.sql；agent/docs/wallclock-realtime-readers.md

[R6] agent/app/modules/hot_news/scoring/hot_score.py；analysis/hot_news_enrichment.py；persistence/hot_news.py（后两项同属 modules/hot_news）

[R7] agent/docs/enterprise-audience-implementation.md；agent/docs/local-behavior-tags.md

[R8] agent/app/modules/knowledge/tier_lifecycle*.py；agent/docs/tiered-knowledge-lifecycle.md

[R9] agent/tests/；agent/app/config.py；DemoMD/PROJECT_CONTEXT.md

公开技术资料（2026-10-25 查阅）

[E1] 腾讯云《TDSQL-A PostgreSQL版 产品简介》，产品概述更新于 2022-04-14；仅支持技术方向，不证明内部版本。
https://main.qcloudimg.com/raw/document/product/pdf/1378_54432_cn.pdf

[E2] 腾讯云《TDSQL PostgreSQL版 创建只读账号》，更新于 2024-09-14；实际内部授权另行确认。
https://cloud.tencent.com/document/product/1129/78793