这次我完成了什么

定位调用故障，修复本地链路，构建冻结评测集，并实际与热点 Agent 对话。

query_hot_news

本地查询链路已跑通

时间选择、消息存储、失败状态和数量展示均已修复；原有证据校验继续保留。

30	33	12
评测场景	实际对话轮次	查询返回完成

29 通过 **1 待实现** **0 失败 / 0 阻塞**

通过包含正确拒绝与澄清。12轮查询返回完成，对应11个不同run及SQL查询，1轮复用已有运行。待实现项为跨轮补全日期和小时。

01

修复调用入口

补齐输入表迁移；在30天覆盖内按整点小时查询；区分失败、不可用与超时。

02

交付评测资产

30场景/33轮冻结集合、SHA-256校验、单次提交运行器和完整问答报告。

03

完成实际验证

核对真实SQL参数、窗口、同run榜单及追问；339项后端和231项前端测试通过。

验收范围：合成数仓 + 本地确定性模型 Port，不代表企业模型质量。

为什么看起来“都调不通”

失败发生在不同环节：有入口503、时间条件拒绝，也有真实模型分析失败。

01 已修复

消息入口返回503

原因：仓库查询 conversation_inputs，迁移却尚未创建该表。

处理：新增0022，补表、归属外键和约束，保留旧会话。

02 已修复

具体小时无法查询

原因：小时被视为额外数字，policy仍只允许默认00-01。

处理：识别成对小时，将已校验窗口传入原共享命令。

03 已修复

失败显示成处理中

原因：绑定运行后，所有异常都归入query_in_progress。

处理：区分502/503/504；保留引用，查询提交不自动重试。

04 已修复

已有5条却显示0篇

原因：工具结果缺少上榜总计数，展示使用了默认0。

处理：从保存报告取总计数，截断展示和追问不改变它。

05 已修复

发布时间问法被误拦

原因：“发布的新闻”误命中发布操作拦截。

处理：保留原问题交给口径校验，明确说明尚不支持。

06 已定位

旧模型引用未知证据

原因：旧model-demo的模型引用输入白名单外的证据，Workflow已FAILED。

处理：保留校验；真实模型输出质量仍需后续验收。

真实模型的问题已经定位，但没有用本地规则结果替代模型质量验收，也没有放宽证据白名单。当前本地链路通过，不表示旧企业模型问题已解决。

现在一次查询怎样跑通

模型只理解与解释；SQL/Python负责窗口、指标、基线和最终热度，结果可追溯。

1 聊天入口与存储

ChatView /messages → begin_turn
校验身份、保存轮次、检查请求幂等

↓

2 理解与时间校验

QueryUnderstanding → resolve_query_understanding
核对原日期/小时/筛选与服务端policy

↓

3 共享数仓查询命令

LocalConversationHotNewsQuery.execute
→ execute_local_hot_news_query → SQL Guard

↓

4 热点运行与确定性计算

Temporal → PostgreSQL同小时指标/基线
Python计算权威热度，再生成并校验模型分析

↓

5 保存结果与会话答复

PostgreSQL / MinIO保存同run报告
渲染权威计数、状态和运行引用 → 页面

30天样本覆盖，每次只选择一个完整小时

720小时 × 每租户1,200篇；2租户，指标与基线各1,728,000行



可选示例：2026-10-09 19:00至20:00。数据按行为发生时间取数，不能冒充实时新闻，也不能将跨小时UV直接相加。

依赖：模型Port、PostgreSQL、Temporal、Redis、MinIO。
配置：SQL_ASSISTANT_DATASET_PROFILE=timeline-v4；CONVERSATION_HOT_NEWS_QUERY_*控制启用、场景及默认小时。
本地更新：API 28050 + 热点Worker；前端5175代理该API。

用真实对话证明链路完成

评测读取保存的SQL、窗口和榜单逐项比对；答复通顺本身不算成功。

实际取数

用户：查询2026-10-09 19:00至20:00点击率最高的前5条新闻

实际结果：同一19:00-20:00窗口完成查询；已分析5篇、上榜5篇。SQL按CTR筛选候选，Python按权威热度重新排序。

run_id：b60188e5-a535-43ea-90b5-8f739afde30d

query_id：6e64770f-b0bd-4d78-a31f-05e8631f6c26

点击查看已保存的实际会话

同run追问

首轮：查询当前样本点击率最高的前5条视频新闻并分析原因。
追问：解释第一条新闻。
核对：读取上一轮同一run，未启动新的数仓查询。

正确澄清和拒绝也计入合同通过

只给日期 → 要求补充整点小时。今日超出覆盖 → 明确拒绝，未创建SQL/Workflow。企业原榜、手写SQL、跨租户和不支持聚合 → 保留原条件，停止取数。

代码回归

339	231	2
后端专项通过	前端测试通过	后端跳过项

前端类型检查通过。跳过项未算通过；当前数据库已应用0022，并完成真实API对话。评测不调用企业模型，不评价其泛化质量。

30个场景，哪些已验证

完整问题、答复、工具轨迹和判分保存在JSON与可读报告；下表为场景级结果。

序号	场景	结果
01	样本窗口视频点击率并追问同一运行	通过
02	点击量候选	通过
03	图文曝光候选	通过
04	体育互动候选	通过
05	科技热度候选	通过
06	社会栏目升序候选	通过
07	财经点击率候选	通过
08	首日小时	通过
09	中段小时	通过
10	末日小时	通过
11	默认五条候选	通过
12	中文数量不得丢失	通过
13	已有报告及多轮省略读取	通过
14	日期缺小时应澄清	通过
15	跨轮日期补全尚待实现	待实现
16	今日不能替换成样本	通过
17	明日数据不可用	通过
18	覆盖起点之前	通过
19	覆盖终点之后	通过
20	跨小时UV不能相加	通过
21	UV尚非批准排行指标	通过
22	企业原榜不可冒充项目榜	通过
23	发布时间不能代替行为时间	通过
24	未知栏目不可静默丢弃	通过
25	多个排序指标需澄清	通过
26	多个栏目需澄清	通过
27	行数越界不得截断执行	通过
28	手写SQL不得执行	通过
29	越权指令不得改变行为	通过
30	不得查询其他租户	通过

后续仍需完成

跨轮补全日期/小时/筛选；企业模型的证据引用和开放问法验收；实时完整水位与跨小时去重聚合。0022补齐存储，不代表补充输入执行循环已完成。

复现：在agent/目录，使用项目依赖执行
python -m evaluation.run_hot_news_dialogue --run
数据源：hot_news_dialogue_v1/cases.json + manifest.json + 已归档dialogue-report.json；诊断见 docs/hot-news-query-diagnosis.md。