NEWSAGENT / REAL NEWS WAREHOUSE / V8

真实新闻 + 模拟行为：可查询的数仓底座

661 篇不同真实新闻 · 7 个业务栏目 · 2 个隔离租户 · 2,476,892 行聚合与管理数据

标题、正文、URL、发布时间来自公开缓存；点击与访问指标均为模拟值。此架构用于本项目演示。

1 真实内容

公开页面缓存
661 篇原文，保留来源与正文摘要
以真实 news_id 关联所有表

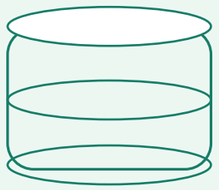
科技 / 财经 / 体育 / 社会
汽车 / 教育 / 娱乐
栏目为演示标签，带来源说明

2 模拟统计

曝光 → 点击 → 详情访问
允许搜索、外链等直接访问
人数用临时集合并集去重

无企业用户行为明细
同一 seed 生成同一份数据
新闻发布之前没有行为

3 数仓存储



news_sim_v8

12 张表 · SQL / JSONL / 校验摘要

4 后续 Agent

只读、参数化查询
按租户 + news_id + 窗口取数
Python 计算，模型解释

已有 18 字段兼容视图
访问 PV / UV 用独立统计接口
本次完成底座，运行接入待做

五分钟、渠道都对齐小时；日 UV 另行去重

过去同小时 → 基线

五分钟
1,739,966 行
完整历史桶 / 修订桶

渠道小时
438,036 行
推荐、搜索、推送等

新闻小时
146,012 行
跨渠道统一口径

新闻每日
6,980 行
跨小时去重 / 末日部分

历史基线
143,368 行
过去3天同小时 / 缺失NULL

一篇真实新闻，怎样得到业务统计？

WorkBuddy开放平台上线，AI办公迎来硬件入口之争

真实 ID 20260903A05YQE00 · 模拟窗口 2026-10-14 19:00（北京时间）

曝光	点击	点击人数	访问 PV	访问 UV
1,323	81	41	401	245

CTR = 点击 / 曝光 = 6.12%；访问 UV 是去重人数，不能把渠道或小时 UV 相加。

查询前的三道门

① 最新修订 + 水位完整 + 质量通过
② 发布状态可用 + 无屏蔽墓碑
③ 租户 / 版本 / 数据摘要一致

撤稿与清理只在隔离租户演练；
清理任务全部 pending，未删除实际向量。
真实撤稿通知与索引执行器留待后续接入。

窗口 2026-09-30T00:00 → 2026-10-14T20:00 | 流式摘要校验 + PostgreSQL 16 导入与对账通过

原文 news.qq.com/rain/a/20260903A05YQE00 | Dataset a933780d744f0e95447f… | 单页矢量图，可放大查看