NEWSAGENT / STABLE FIRST RELEASE / 2026-10-15

第一版：复用企业中间件，把三层召回跑稳

Python API + 索引Worker；三层先放同一受管向量服务，限定首批万级数据，先验收内容正确与故障恢复。

这是接入建议：企业具体服务与配额待确认；现有Milvus查询已接线，增量写入/更正/撤稿同步尚需补齐。

入库与变更：先持久保存任务，失败后可恢复

企业内容接口
正文 / 发布时间 / 版本
撤稿状态 / 增量游标

→

PostgreSQL
文档与版本台账
同一事务写待处理任务

→

Temporal + Worker
复用现有调度
切片 / 限流 / 有界重试

→

统一Embedding
固定模型版本与维度
批量生成 / 校验向量

→

受管向量服务
优先现有Milvus适配
写入 / 验证 / 删除

验证目标版本可检索 → 提交有效版本/所在层 → 清理旧投影；迁移失败保留源层，任务和进度留在数据库。

一个向量服务，三个逻辑集合

HOT
新稿 / 活跃内容
优先处理变更

WARM
降温内容
定时迁移与对账

COLD
历史内容
回溯与旧闻回热

首版统一模型与索引类型，预加载验收集合；三集合本身不会保证冷热延时差异。

查询：身份可信，证据返回前复核

企业网关 → Python API → 同版本Query Embedding
→ 三层并发召回 → 按PG版本/撤稿状态过滤
→ 每新闻仅一次贡献与输出 → 融合结果 / 证据
统一总超时、限制候选量和并发；PG不可用时停止输出证据。

稳定运行的关键：撤稿与更正跨三层生效，不能只等向量物理删除

新增积压
任务落库后处理
有效存量仍可查询

内容更正
旧版先失效
新版可检索后放行

撤稿
台账先屏蔽所有出口
异步删除三层旧切片

失败 / 乱序 / 重复
按版本拒绝旧事件
幂等恢复，失败告警

向企业平台申请的接入资料

内容API与更新/撤稿合同；Embedding模型、维度、限额。
PG库/账号/备份；向量地址、三集合、权限、一致性和配额。
Temporal命名空间/任务队列；部署、网关、密钥、日志与监控入口。

复用项目现有依赖，首版少加系统

Redis继续服务现有缓存/SSE；S3继续保存报告与评测资产。
索引任务状态以PG为准，调度复用Temporal；无需新增专属MQ。
日志/指标/告警接企业现有平台；物理冷热分离与压缩后续再评估。

建议验收：连续48小时 + 杀Worker/断Embedding/断向量服务 + 新增/更正/撤稿/迁移/重复事件；恢复后任务不丢。

监控：任务积压与最老等待、更新可见延时、撤稿残留、各层p95/失败率、连接池与资源；延时阈值由实测约定。

待补：持久化索引工作流、跨层版本/撤稿Gate、迁移恢复、查询路径统一及企业合同验收；本图未修改运行配置。