索引怎样建成，参数怎样得到，效果怎样验收

v2：20,187 篇 / 50,252 切片 · 固定包摘要 c59a3095657711fb… · 本轮未改索引与部署

结论：图近似精度在本次工程样本中很高；800 字切片与 512 token 窗口存在覆盖缺口；人工语义质量尚待标注。

1 构建链：只追加新向量，合并后重建整张图

已有 v1 快照

12,728 篇 / 38,026 片
旧 JSONL 行与向量原样保留

不重切、不重算旧向量

按行号合并向量矩阵

50,252 × 1024 float32
label = JSONL 行号 0…50,251

HNSW 建图（层级示意）



IP / M=32 / ef_construction=200
seed=100 / threads=4
在全部合并向量上重新插入、连边

8,000 篇冻结原文

校验文件 / 正文 / 来源 / 时间
541 个已有 ID 跳过
新增 7,459 篇 / 12,226 片

确定性切片与输入头

正文 800 字 / 重叠 80 字
每片重复标题 + URL + 时间
实际输入仍受 512 token 限制

本地 BGE 文档编码

MPS / FP16 / batch 8 / CLS
无 query 前缀，输出 1024 维
转 FP32 + L2，批次散回原行序

chunks.jsonl ↔ embeddings.npy ↔ index.bin（同行身份） → SHA256SUMS / 回执 → 原子 rename 新包 → API / Worker 显式切换

2 参数来源：模型约束、工程固定值、资源选择、查询配置

模型决定

1024 维 / CLS / 最大 512 token
512 包含特殊 token；头部也占预算
不可只把序列长度调到 800/1024

构建器固定

新片 800/80；M32；efc200；seed100
容量由总行数得到：50,252
当前未证明这些值是质量最优

本机资源选择

MPS / FP16 / batch8 / threads4
为控制内存；落盘仍 FP32
小数值探针不能替代排序质量评测

查询 YAML

ef256 / chunk_pool200
实际 ef=max(配置ef,当前pool)
池不足翻倍；ef64/128会被抬至200

3 严格评测：工程结果已测，语义验收不能跳过人工标签

编码输入覆盖：已发现缺口

新增片段 54.79% 超过 512 token
3,487 / 7,459 篇存在正文区间缺口
扣除切片重叠后，字符覆盖 74.98%
未覆盖 1,525,335 字符；可逐篇追溯
这是输入区间覆盖，不是语义损失比例

HNSW 对精确 IP：工程探针

旧/新各48个源向量；排除源新闻所有片
文章 ANN@20 = 99.9479%（ef256）
条件 bootstrap 95%：99.8437%…100%
p50 1.76ms / p95 2.78ms
无编码/HTTP/并发；不等于用户问句质量

新闻相关性：等待双人盲标

36 个草稿问题 / 576 个待判断候选
0…3级：无关 / 背景 / 有用 / 核心相关
事件组隔离 dev / validation / test
池内 Recall / nDCG、P@3、无答案误接收
未判 TopK / 草稿 / 缺预测 → 阻断评分

待办：人工试标校准 → token预算切片候选 → FP16/FP32与图参数对照 → validation选参 → 冻结test → 人工审核发布

数据：source-index-verification / tokenization-audit / ann-report；协议：agent/evaluation/news_retrieval_protocol.v1.json