把数仓想成新闻运营的“物流枢纽”

行为数据送来账目，内容系统送来正文，生命周期送来通行规则；Agent 在下游组合这些证据。

绿色：本地已有　　虚线：目标接线 / 待实现　　腾讯新闻内部技术栈待确认

行为线路

曝光、点击、消费、互动
上游企业平台负责原始采集

内容线路

新闻正文、来源、发布时间
图文、视频文本化、QA

状态线路

发布、更正、撤稿、受限
可信内容状态 + 版本事件

运营数仓 = 账本

按时间、新闻、渠道保存聚合
回答：谁受关注，变化多大？

知识库 = 图书馆

文档与切片是事实台账
向量是可重建的检索目录

资格门禁 = 通行闸门

当前状态、墓碑、清理任务
决定：此刻还能否使用？

NewsAgent = 运营工作台

受限 SQL 读取权威指标
+ 正文与关联证据
+ 当前内容资格

Python 计算排行和校验
LLM 解释、总结、辅助写作

当前落点

v7 已生成隔离 PostgreSQL 数据包和资格视图；既有 v6 热点链路独立于本包。v7 到 Agent、正文和向量库的连线尚未接入。

13 张表：给谁记账、记什么、何时可用

每张表先看“一行是什么”。共同关联键是 tenant_id + news_id；表数多，是因为职责不同。

A 身份证与字典 · 3 表

dim_news

一租户一新闻：题材、形态、版本、状态

dim_publisher

一租户一来源：媒体、创作者等合成类型

dim_channel

一租户一渠道：推荐、搜索、推送等

B 运营账本 · 3 表

news_metric_5min

新闻 × 渠道 × 五分钟 × 修订

news_metric_channel_hourly

新闻 × 渠道 × 小时 × 修订

news_metric_hourly

新闻 × 小时 × 修订；跨渠道 UV

C 通行与清理 · 3 表

content_change_event

可信变更事件：更正、撤稿、受限

content_tombstone

撤稿 / 受限内容的持久屏蔽记录

index_cleanup_task

分目标、分版本的待清理任务

D 质检与参照 · 2 表

window_snapshot

小时 × 修订：水位、完整性、版本

news_metric_baseline_hourly

同新闻前 1-3 天相同小时的均值

E 原榜快照 · 2 表

board_snapshot

榜单 × 快照：时间与规则版本

board_item

原始名次、位置、分数；保留并列

视图 = 服务柜台

最新修订 + 完整窗口
+ 当前可用内容 + 空基线保留
→ 18 列兼容查询投影

记住四个约束

租户隔离；计数关系校验；修订号绑定；内容资格过滤。视图只是投影，历史账本与当前可用结果可以不同。

一篇新闻：点击可以相加，人数要去重

下面直接取 v7 数据包的合成样例：租户 A、案例 001、2026-10-13 23:00-24:00、修订 2。

推荐信息流

442 次点击

173 人 / 渠道小时 UV

搜索结果

488 次点击

180 人 / 渠道小时 UV

消息推送入口

492 次点击

185 人 / 渠道小时 UV

次数账：442 + 488 + 492 = 1,422 次点击

人数账：173 + 180 + 185 = 538，但去重后是 261 人

为什么少了？同一个人会跨渠道重复消费

UV 保存并集结果。v7 用临时合成区间模拟重叠，只落聚合人数；小时 UV 也不能相加后称为全天去重人数。

比例必须由总量再计算

CTR = 1,422 / 18,496 = 7.69%

不直接平均各桶 CTR；零分母保留 NULL。
有效消费、时长和互动均由 Python / SQL 算。

桶怎么变成小时？

每渠道 12 个五分钟桶 → 渠道小时聚合 → 新闻小时聚合。当前细桶文件仅保留最后闭合小时两次修订和开放小时。

到整点，不等于这一小时已经完整

把窗口看成一只“封箱快递”：event_time 是货物归属时间，snapshot_at 是盘点时间，水位和质量决定能否交付。



第一次盘点 · rev1

最后闭合小时
水位 23:45 / 快照 23:50
incomplete + pending
还不能进入完整小时榜

补数后的盘点 · rev2

同一闭合小时
水位 00:10 / 快照 00:15
corrected + passed
最新且完整，才可进入榜单

进行中的新小时

开放小时 rev1
水位 00:30 / 快照 00:35
只生成 7 个五分钟桶
仍然 incomplete + pending

查询的顺序

1 先挑最新修订

固定租户 + 小时 + revision

2 再验完整与质量

complete / corrected 且 passed

3 才输出可用结果

不回退旧修订冒充本次数据

水位要配合合同使用

它表达事件时间进度；还需迟到预算、来源覆盖和质量校验。当前 v7 离线模拟这些状态，持续流消费和实时服务仍待实现。

数字、正文、向量：各自回答不同问题

数仓回答“多少、何时、怎么变”；正文回答“发生了什么”；向量帮你找到有关材料。三者由新闻身份连接。

运营数仓 · 账本

曝光、点击、UV、时长、互动
基线、窗口、水位与数据版本
权威数字来自 Python / SQL

文档台账 · 图书馆

正文、来源、文档和切片版本
必要证据与派生血缘
向量删除不替代文档状态治理

向量索引 · 检索目录

Embedding → 相关材料候选
Milvus / BGE 等检索 Adapter
相似度不能作为新闻热度

统一身份：tenant_id + news_id；正文版本、生命周期修订、数据版本分别保留

现有热点运行：下面的流程已经有本地链路

提问 / 调度

身份与有界窗口

→

受限 SQL

意图 → 编译 → 校验

→

Python 指标

候选 → 热度排行

→

正文与证据

精确新闻 + 关联召回

→

LLM / 校验

分析表达 → 保存报告

v7 隔离数据包

新 schema / 13 表 / 5 视图
已导入验证；包含合成标题，无正文或向量

⇢

待接入上面的共享运行

注册新契约和白名单，绑定窗口修订及质量证据，建立正文 / chunk 映射，并复用现有热点 Workflow。

撤稿像关闭通行闸门，再清理各处副本

先让内容不可再使用；向量删除可以异步执行，删除失败也不应该恢复可见性。

v7 已有：事件、墓碑、SQL 资格过滤、pending 任务

真实读链门禁 / 删除 Worker 待接

1 收到可信撤稿

租户 + 新闻 + 状态修订

2 提交状态与墓碑

立即阻止新证据使用

3 异步清理投影

版本映射、重试、审计

4 验证无被禁版本

验证后才记为完成

同一新闻，在三种存储的处理方式

PostgreSQL 知识台账

停用 / 清理文档与切片
先建立新闻到 chunk 的版本映射
当前缺撤稿状态入口

Milvus 向量索引

按已核对的旧版本 chunk 删除
不能只凭 news_id 跨租户删除
删除后再检查被禁版本残留

BGE / HNSW 只读快照

先在读取侧应用屏蔽名单
再重建并切换新快照
旧快照恢复仍要加载墓碑

防止“删了又回来”：正文版本和状态修订分开

撤稿可以是 content_version=1、lifecycle_revision=2。晚到入库不能自行复刊；旧清理任务只能删绑定的旧版本，不能误删合法新版。

还要处理副本

缓存、QA、视频转写、报告、会话摘要和备份都要有来源血缘与失效规则。现有检索仍缺统一最终状态检查，v7 任务尚未执行真实删除。

现在在哪里，下一步接什么

本册依据当前代码、版本化数据包和保存的验收记录绘制。公开腾讯新闻定位用于业务背景，内部表名与技术栈仍待确认。

240	227,050	33,600	41
合成新闻 / 两租户	13 表总记录数	完整且可用的指标投影	专项测试记录通过

已有：可以复查的本地数据包

6 渠道、4 形态、12 主题、17 类合成模式
计数 / UV / 基线 / 修订 / 生命周期台账
隔离 PG16 导入、只读核对及重复导入拒绝

待接：运行与治理闭环

v7 → Agent 的新契约 / 白名单 / 质量 Port
可信状态门禁 → Outbox / Worker → 真实清理
持续流、企业口径、权限与生产验收

这份图解如何生成

manifest / validation / 聚合 JSONL → load_evidence() 校验文件哈希和样例 → WarehouseArchitectureGuide → ReportLab + 中文字体 → 7 页可缩放 PDF。

配置：--dataset / --output / --font / --bold-font。外部依赖：ReportLab；核验使用 pypdf、pdfplumber、Poppler。测试入口：运行本脚本完成源文件校验，再逐页渲染检查；不调用企业模型或向量库。

依据与延伸阅读（点击可打开）

1. 腾讯新闻公开产品定位 https://www.tencent.com/zh-cn/products/tencent-news/
2. 腾讯云事件时间 / Watermark 通用语义 https://cloud.tencent.com/document/product/849/18034
3. 项目 v7 设计与验收 agent/docs/tencent-news-simulation-v7.md；output/warehouse/tencent-news-v7-20261014/validation.json