评测与训练数据：需要什么、怎么交付

适用前提：企业当前仅提供推理和 Embedding 接口；优先建设评测及训练数据准备。

> 先准备能重放、能判断、能追溯的样本。现在就可开展真实模型评测和 Prompt 实验；SFT/DPO/RL 的实际训练还需要独立训练服务或获准权重与计算环境。

第一批准备五类数据

数据	用途	提供者
新闻与证据快照	保留当时可见事实、来源与版本	内容/知识库团队
有界窗口聚合指标	复算数字、热度及数据完整性	企业数仓 + Python
脱敏问题与运行结果	复现模型及工具错误	项目自动采集
人工标签与完整修订答案	正式评测；未来 SFT	运营/编辑 + 独立复核人
用途、分组、版本与哈希清单	防泄漏、审核、冻结及追溯	数据负责人

先读这些页面

第2-3页：采集清单与字段规范；第4-6页：完整热点输入、正确答案与现有评测格式；第7-8页：意图、对话轨迹与检索评测；第9-11页：SFT、DPO 与 RL 数据；第12-15页：划分、质量检查、项目接入和依据。

文中的三个状态

现有：当前项目 Schema 或服务已支持。拟新增：建议采集/训练契约，当前 API 尚不接受。格式示例：虚构教学数据，审核状态始终 pending，不能冒充真实批准数据或企业效果。

> 交付采用 UTF-8 JSONL + manifest.json + 标注规范。业务人员可先用表格标注，导入时再做强类型转换。所有示例的数字为合成聚合值，未收集企业原始用户行为。

采集清单：由谁提供，收集到什么粒度

按目标任务收集必要字段，无需把所有历史数据或用户行为明细搬进项目。

优先级 / 数据	最低字段与粒度	用途 / 格式
P0 内容与证据	news_id；标题、必要正文片段；栏目/类型；来源；发布时间、更新时间、内容版本；使用授权	重放事实输入 JSONL / 受控内容引用
P0 聚合指标	news_id + tenant_ref + [start,end)；曝光/点击/去重UV/有效消费/互动；watermark；口径与快照版本	复算指标；检查覆盖 JSONL / CSV
P0 基线与热度	可比较基线或显式null；基线窗口/版本；四分量与总分；规则版本	解释主驱动及限制 JSON对象
P0 推理记录	脱敏用户问题、必要历史、模型输入/原输出；Prompt/模型/Schema版本；状态/错误码/耗时	真实评测与错误归因 JSONL
P0 人工评测	对/错/部分错/不可评；必需/禁止证据；指标；允许主驱动；限制；二审与规范版本	正式评测标签 标注表转JSONL
P1 完整修订答案	人工修订后的完整输出，绑定同一输入、证据和Schema；独立复核	未来SFT；不是原错误输出 JSON / JSONL
P1 检索/对话记录	冻结语料与候选池、相关性标签；工具白名单、参数、结果快照、完整性	检索/完整Agent评测 JSONL + 快照引用
P2 偏好/奖励	同输入回答对、偏好理由；终态/奖励分量/环境版本；明确用途授权	未来DPO/RL 待审批契约

> 模型平台另外提供：批准路由和版本、上下文/超时/限流合同、Embedding版本与维度、数据保留及训练使用限制。配置仅保存密钥引用名称，样本不得包含密钥或身份头。

统一样本台账：业务载荷与管理信息分开

以下外壳为拟新增契约；不能原样提交到当前热点输入/评测 API。


```
{
  "schema_version": "newsagent-data-ledger-v1-proposed",
  "sample_id": "demo-sample-001",
  "task_type": "hot_news_analysis",
  "data_kind": "synthetic",
  "scope": {"tenant_ref": "demo-tenant-A", "owner_ref": null},
  "event_group_id": "demo-event-bus-001",
  "conversation_group_id": null,
  "near_duplicate_group_id": "demo-duplicate-bus-001",
  "observed_at": "2026-10-12T10:00:00+08:00",
  "split": "development",
  "split_version": "demo-split-v1",
  "allowed_uses": ["format_validation"],
  "redaction_version": "demo-redaction-v1",
  "source_case_ref": null,
  "retention_until": "2027-01-13T00:00:00+08:00",
  "annotation": {"status": "pending", "guideline_version": "demo-guide-v1", "labeled_by": null, "reviewed_by": null},
  "input_sha256": "9b3597ad504f0475e9048ecb107a987b6b1baf728c1f5e3d6ddaad22f33d0f2a",
  "candidate_target_sha256": "3c9e5327f7e6a7fadb9cb0272dff0cc585395d4b75401b5badde85ad2a0400ed"
}
```


input_sha256 与 candidate_target_sha256 对本册第4、5页完整对象按排序键、紧凑UTF-8 JSON计算；哈希用于完整性检查，不等于人工批准或授权签名。

字段约定	含义与处理
ID与scope	sample_id唯一；scope由服务端绑定。真实身份映射留在企业授权系统；化名仍需治理。
split与allowed_uses	development用于格式开发；正式拆train/validation/test。获准用途不足则排除训练。
annotation	pending/review_pending/approved/conflict/not_evaluable 为拟定状态；二审人与标注人不同。

> 正文input、expected、candidate_target单独存放并按sample_id/内容哈希关联。现有Schema使用extra=forbid，禁止把split、审核人或tenant_ref塞进HotNewsAnalysisInput。

热点分析输入：完整现有 Schema 示例

此对象可按 HotNewsAnalysisInput 做结构校验；新闻、指标及链接全部为虚构。


```
{
  "news_id": "demo-bus-001",
  "title": "虚构示例：青禾市社区接驳线路开始试运行",
  "summary": "交通服务中心公布停靠站点与服务时段，效果待评估。",
  "content_excerpt": "虚构青禾市9时20分公告：线路9时30分试运行，尚无客流与满意度结果。",
  "content_type": "article",
  "window_start": "2026-10-12T09:00:00+08:00",
  "window_end": "2026-10-12T10:00:00+08:00",
  "hot_score": 0.4225,
  "metrics": {
    "impressions": 1000,
    "clicks": 400,
    "ctr": 0.4,
    "unique_users": 700,
    "effective_consumptions": 300,
    "interactions": 60
  },
  "score_components": {"click": 0.12, "consumption": 0.2625, "interaction": 0.04, "growth": 0.0},
  "related_news": [
    {
      "news_id": "demo-bus-plan-001",
      "title": "虚构示例：社区接驳试运行安排",
      "excerpt": "9时10分公告列明站点和时段，客流结果待后续评估。",
      "source_url": "https://example.com/demo/bus-plan-001",
      "published_at": "2026-10-12T09:10:00+08:00",
      "final_score": 0.9,
      "rerank_reasons": ["同一虚构事件", "补充试运行范围"]
    }
  ],
  "analysis_policy_version": "hot-news-analysis-v1",
  "memory_context": null
}
```


窗口为北京时间09:00至10:00，结束不含；证据在观察时点前发布。ctr用0.4表示40%，绝不把40直接填入。unique_users为企业在这个完整窗口内去重后的700，不能跨小时相加。

> Python默认公式：点击0.4×0.30=0.12；消费(300/400)×0.35=0.2625；互动(60/300)×0.20=0.04；无基线增长为0；总热度0.4225。指标与分量来自确定性层，不由模型生成。

完整目标答案：未来 SFT 所需的新增数据

内层兼容现有 HotNewsAnalysisReport；候选答案通过结构校验，人工复核仍为 pending。


```
{
  "news_id": "demo-bus-001",
  "trend_assessment": "点击率40%，有效消费300次；消费分量最高。缺历史基线，不能判断关注上升。",
  "dominant_driver": "consumption",
  "attention_reasons": [
    {
      "reason_type": "metric",
      "statement": "有效消费占点击75%，消费分量为0.2625。",
      "metric_keys": ["effective_consumptions", "clicks", "consumption_component"],
      "evidence_news_ids": [],
      "confidence": 1.0,
      "certainty": "observed"
    },
    {
      "reason_type": "hypothesis",
      "statement": "实用信息可能与阅读有关，但无法验证因果。",
      "metric_keys": ["effective_consumptions"],
      "evidence_news_ids": ["demo-bus-plan-001"],
      "confidence": 0.45,
      "certainty": "inferred"
    }
  ],
  "related_contexts": [
    {
      "statement": "线路仍在试运行，客流效果待评估。",
      "evidence_news_ids": ["demo-bus-plan-001"],
      "confidence": 0.95
    }
  ],
  "operation_suggestions": [
    {
      "action": "建议运营审核后补充站点和服务时段。",
      "rationale": "提供实用信息，避免把试运行写成效果获证实。",
      "priority": "medium",
      "metric_keys": ["consumption_component"],
      "evidence_news_ids": ["demo-bus-plan-001"]
    }
  ],
  "evidence_news_ids": ["demo-bus-plan-001"],
  "applied_memory_ids": [],
  "limitations": ["全部内容与数字均为虚构示例；链接为占位地址。", "无历史基线；增长分量为0不表示没有增长。", "单小时聚合不
    能证明线路运营效果。"],
  "overall_confidence": 0.85,
  "output_schema_version": "1.0"
}
```


> reason_type=hypothesis必须certainty=inferred。applied_memory_ids为必填，未用Memory时填[]。正确引用ID只证明来源合法，还需要人工判断语义是否被证据支持。

现有评测格式：规则标签不是完整答案

保留原输出用于归因，使用独立标签验收。当前离线热点 Schema 与正式冻结账本是两种入口。

现有 ExpectedHotNewsAnalysis 的完整标签示例

```
{
  "allowed_dominant_drivers": [
    "consumption"
  ],
  "required_evidence_news_ids": [
    "demo-bus-plan-001"
  ],
  "forbidden_evidence_news_ids": [
    "demo-other-city-001"
  ],
  "required_metric_keys": [
    "effective_consumptions",
    "consumption_component"
  ],
  "must_state_limitation": true
}
```

禁止ID可以是没有出现在允许输入中的其他主体。允许多个合理主驱动；不要求模型逐字复制标准文章。正式Feedback标签还需verdict及operator_comment，并完成独立二审。

组装现有离线评测数据集：完整结构

```
dataset = {
  "dataset_name": "hot-news-format-demo",
  "dataset_version": "2026-10-13.demo-v1",
  "schema_version": "1.0",
  "description": "虚构格式样例，非正式批准数据。",
  "cases": [{
    "case_id": "demo-eval-001",
    "description": "消费主驱动；无历史基线。",
    "tags": ["synthetic", "no-baseline"],
    "analysis_input": input_object,  # 第4页完整对象
    "expected": expected_object     # 本页完整对象
  }]
}
```

上面是Python组装代码，不是JSON中的引用语法。序列化后analysis_input和expected必须为完整对象；当前加载器不支持$ref。正式冻结必须通过Feedback→标签二审→Freezer，不能用此demo绕过审批。

> 现有 observed_output 是原模型结果，可能正是错误答案。新增candidate_target经二审后才能转reviewed_target；不把标签字段直接当SFT completion。

问句理解与对话：评测语义和执行行为

外层为拟新增台账；expected_proposal字段对齐现有QueryUnderstanding。该小时覆盖需由测试policy明确提供。


```
{
  "sample_id": "demo-query-001",
  "task_type": "query_understanding",
  "question": "查2026年10月12日9点至10点点击率最高的前5条视频新闻。",
  "as_of": "2026-10-12T10:00:00+08:00",
  "timezone": "Asia/Shanghai",
  "policy_snapshot_ref": "demo-approved-hour-policy-v1",
  "expected_proposal": {
    "status": "ready",
    "intent": {
      "sort_by": "ctr",
      "sort_direction": "desc",
      "content_type": "video",
      "category": null,
      "row_limit": 5,
      "explanation": "按该小时视频新闻点击率降序选5条。"
    },
    "time_expression": "date",
    "explicit_date": "2026-10-12",
    "hour_start": 9,
    "hour_end": 10,
    "time_basis": "behavior",
    "ranking_source": "unspecified",
    "response_style": "list",
    "unsupported_conditions": []
  },
  "expected_behavior": {
    "must_match_requested_window": true,
    "allow_raw_sql_from_model": false,
    "followup_must_reuse_run": true
  },
  "annotation_status": "pending"
}
```


模型只提出语义；服务端决定时间覆盖、权限、watermark与SQL编译。不能因为status=ready就认为查询一定可执行；现演示环境可能只覆盖另一日期。

多轮工具记录：每一步保存这些字段

turn_index、脱敏user_text、冻结history_refs；step_id、tool_name、validated_arguments、status、attempts、error_code、elapsed_ms、result_snapshot_ref与哈希；request/run/query引用。实际ID只在执行后绑定，不能由模型编造。

> 第二轮“解释第一条”：预期复用首轮已完成run；验证结果引用与顺序，不要求唯一工具路径。保存完整可公开轨迹与真实工具结果，勿收集隐式思维链。未提交的中途轨迹须标incomplete，不能当完整任务成功样本。

检索评测：问题、冻结语料和相关性标签

下列为拟新增检索评测格式；当前热点related_news快照无法独自复现整个召回过程。


```
{
  "sample_id": "demo-retrieval-001",
  "task_type": "retrieval",
  "input": {
    "query": "青禾市接驳试运行的范围与限制",
    "source_news_id": "demo-bus-001",
    "as_of": "2026-10-12T10:00:00+08:00",
    "corpus_snapshot_id": "demo-corpus-v1",
    "filters": {"tenant_ref": "demo-tenant-A"},
    "exclude_news_ids": ["demo-bus-001"],
    "top_k": 5
  },
  "expected": {
    "judgment_unit": "news",
    "relevance_scale_version": "demo-0-3-v1",
    "qrels": [
      {"news_id": "demo-bus-plan-001", "content_version": 1, "grade": 3},
      {"news_id": "demo-other-city-001", "content_version": 1, "grade": 0}
    ],
    "judged_pool_ref": "demo-pool-001",
    "no_relevant_result": false,
    "forbidden_news_ids": ["demo-other-tenant-001"]
  },
  "observed": null,
  "annotation_status": "pending"
}
```


还需冻结	用途
语料及候选池	corpus文件哈希、文档/切片版本、已判断候选集合；避免把缺召回归因成模型生成错误。
实际命中	rank、news_id/chunk_id、原始/最终分数、Embedding/索引/重排版本与片段哈希。
权限与截止时间	查询租户/授权过滤、发布时间上限、源新闻排除；与线上相同。

> 建议相关性等级：0不相关，1弱背景，2相关，3直接支持；具体判断需人工规范。按news或chunk选定一种计分单位。未标注结果不自动当不相关；报告judged覆盖。Recall@K、nDCG@K、MRR之外，单独统计越权与未来证据。

SFT：从审核答案导出训练平台格式

现阶段准备数据；当前企业接口不能训练。下面是拟新增导出逻辑，未接入生产服务。

最终每行采用prompt/completion，或平台要求的messages。项目治理信息放独立台账；模型看不到split、审核结论、参考标签和未来结果。完整目标来自第5页同输入下的人工修订答案。

```
import json
from app.schemas.hot_news import HotNewsAnalysisInput, HotNewsAnalysisReport

# 拟新增导出函数；service注入获准的PromptRegistry与模型Port。
def to_sft_row(case, service, prompt_version):
    if case["annotation"]["status"] != "approved":
        raise ValueError("human review is required")
    if "sft_training" not in case["allowed_uses"]:
        raise ValueError("training use is not authorized")
    if case["split"] != "train":
        raise ValueError("held-out samples must not be exported")
    inp = HotNewsAnalysisInput.model_validate(case["input"])
    target = HotNewsAnalysisReport.model_validate(case["reviewed_target"])
    # 实际导出前还须经过业务Validator和完整性检查。
    rendered = service.render_input(
        scene="hot_news_analysis", prompt_version=prompt_version,
        payload=inp, output_type=HotNewsAnalysisReport,
    )
    prompt = [{"role": m.role, "content": m.content}
              for m in rendered.messages]
    completion = [{"role": "assistant", "content": target.model_dump_json()}]
    return {"prompt": prompt, "completion": completion}

# 每条样本独立序列化；下列参数由获准导出任务提供。
row = to_sft_row(approved_case, service, approved_prompt_version)
line = json.dumps(row, ensure_ascii=False, allow_nan=False) + "\n"
# 如平台要求messages：{"messages": row["prompt"] + row["completion"]}
```

> render_input必须复用拟上线的批准Prompt版本：system中包含完整输出JSON Schema，user中包含冻结输入。勿使用简化一句话Prompt代替真实线上输入。训练框架的chat template、tokenizer、截断与只对目标答案计loss的配置另行锁定。

本册虚构样例annotation=pending、用途仅format_validation，必须被正式SFT导出器拒绝。含私人memory_context的输入默认排除共享训练；需独立用途审批，或重新构造并复核移除私人上下文后的输入和目标。

DPO：同一输入下的偏好回答对

可选未来数据。短答例仅演示通用偏好格式；生产热点分析应保留完整结构化Report。

```
{
  "prompt": [
    {
      "role": "system",
      "content": "仅根据给定聚合和事实解释，明确数据局限。"
    },
    {
      "role": "user",
      "content": "点击400，曝光1000；无历史基线。试运行效果待评估。请解释。"
    }
  ],
  "chosen": [
    {
      "role": "assistant",
      "content": "点击率为40%。缺少历史基线，不能判断关注上升；试运行效果尚待评估。"
    }
  ],
  "rejected": [
    {
      "role": "assistant",
      "content": "关注大幅上升，接驳线路成功改善了出行，建议立即推送。"
    }
  ]
}
```

偏好台账还要记录什么

字段	要求
prompt/input_sha256	两份回答必须面对相同问题、证据、权限、工具结果和观察时点；不能拿不同新闻候选直接组成一对。
preference_kind/reasons	区分事实错误、因果过度、引用错误、编辑表达、个人风格和策略约束；tie/不可评单独保存。
owner_ref/share_approval_ref	个人偏好只在批准作用域内使用；不能自动晋升全租户标准或共享模型训练数据。
review与用途授权	人工选择并独立二审。例中chosen更谨慎，rejected把相关性写成因果且跳过运营审核；示例仍pending。

> 通用字段是prompt/chosen/rejected。实际热点导出使用第9页的同一render_input，content为完整Report JSON字符串；目标模型的格式由训练合同决定。先保障事实与边界，再评文风。

RL：现在记录轨迹，未来再计算奖励

以下为拟新增研究记录。奖励为空表示未执行，不是训练失败，也不能虚构奖励成绩。


```
{
  "sample_id": "demo-trajectory-001",
  "data_kind": "synthetic",
  "task_type": "dialogue_tool_use",
  "environment_version": "demo-env-v1",
  "trajectory_ref": "demo-dialogue-001",
  "prompt_snapshot_ref": "demo-turn-input-001",
  "terminal_status": "not_executed",
  "metrics": {"task_success": null, "tool_call_count": null, "elapsed_ms": null, "token_usage": null},
  "reward": {
    "status": "not_computed",
    "policy_version": null,
    "hard_failures": [],
    "components": null,
    "total": null
  },
  "allowed_uses": ["format_validation"],
  "annotation_status": "pending"
}
```


未来可验证奖励的构成

类型	建议依据
硬失败	越权、未来证据、伪造来源、数字篡改、绕过审批；上线继续由确定性护栏阻断，奖励不能赋予权限。
任务质量	正确意图/澄清、证据真正支持结论、完成真实工具任务；语义评审与独立测试校准。
效率	任务成功前提下减少冗余工具、延迟与token成本；不能奖励只拒绝所有问题。
版本	prompt/环境/工具/模型、reward代码与权重、rollout种子、预算、失败规则均可追溯。

> 现有evidence_precision是“无禁止证据case占比”，不是语义支持率；不能直接作为主要reward。运营采纳和CTR受曝光、时效、人群等影响，不能直接当因果收益。评测器/奖励调参用validation，test保持独立。

数据划分与 manifest：防止答案泄漏

风险层与训练切分是两个维度。此清单为单样本格式演示，approved_case_count=0。


```
{
  "schema_version": "newsagent-data-manifest-v1-proposed",
  "dataset_name": "newsagent-format-demo",
  "dataset_version": "2026-10-13.demo-v1",
  "purpose": "format_validation",
  "data_kind": "synthetic",
  "source_cutoff_at": "2026-10-12T10:00:00+08:00",
  "case_count": 1,
  "independent_event_count": 1,
  "approved_case_count": 0,
  "split_version": "demo-split-v1",
  "guideline_version": "demo-guide-v1",
  "redaction_version": "demo-redaction-v1",
  "serialization": "UTF-8; json.dumps(indent=2,ensure_ascii=False) + LF",
  "files": [
    {
      "path": "hot_news_input.json",
      "file_sha256": "4f5bf840f9bcb3d8ad8a4dad42611906925b9193d104b9f351558e7330476212"
    },
    {
      "path": "candidate_target.json",
      "file_sha256": "c4294e70a9937bcace708f15a0849fce72656babbf9b5aa806fc09326779e5da"
    }
  ]
}
```


file_sha256按清单声明的实际UTF-8序列化字节计算；与第3页规范JSON对象哈希的算法不同。正式交付必须校验真实文件字节，不能拿PDF文本复制后的字节直接比较。

划分的五条规则

1. 同一事件、转载、切片、更新阶段、运营候选和近重复问题保持同split。
2. 同一会话各轮保持同split；有交叉关联时按连通组一起划分。
3. 同时约束观察时间；任何输入不得带未来事实、标签或投递结果。
4. train用于训练；validation用于选Prompt/奖励/超参数；test单独冻结。
5. Golden/Fresh/High-risk可能重叠，统计独立case/event数量；test若用于修复，登记污染并更换独立测试版本。

交付目录与质量验收：业务团队照单准备

下面是建议交付包，不是本次已生成的数据文件。先做小批试标与复核，再根据错误分布扩量。

```
newsagent_data_delivery/v1/
  manifest.json              # 版本、文件哈希、数量、用途
  collection_ledger.jsonl    # scope/group/split/授权/审核
  hot_news_inputs.jsonl      # 第4页业务输入
  evaluation_labels.jsonl    # 第6页规则标签
  candidate_targets.jsonl    # 第5页完整人工修订候选
  retrieval_cases.jsonl      # 第8页相关性与语料引用
  dialogue_cases.jsonl       # 第7页问题、历史及轨迹
  annotation_guide.md        # 口径、例外、冲突与复核
  snapshots/                 # 获准内容、工具/语料快照
  sft_train.jsonl            # 将来审核/授权后才导出
  preference_train.jsonl     # 可选未来DPO数据
```

验收项目	通过条件
完整与一致	必填字段/枚举合法，引用存在，哈希匹配；CTR与热度可复算；缺基线/水位显式记录。
隐私与用途	无原始行为、密钥、个人标识、签名URL或未授权片段；用途与保留期限清晰。
人工复核	标注人与复核人不同；冲突/不可评排除正式冻结；完整答案评事实和语义。
防泄漏	split组交集为0；查近重复；无未来证据、test回流或个人偏好越作用域。
评测报告	失败/缺答保留固定分母；不可评数量另报；双基线同输入；分板块/风险与独立事件计数。

> 不能用合成条数或重复快照证明真实泛化；当前432运营候选来自36虚构主线，且待人工复核。质量门禁、分层数量和可接受退化幅度应在实验前审批，不能用宽松默认值当生产标准。

项目接入调用链：复用哪里，补哪里

本次交付仅为PDF与可重复生成源码；未修改业务Schema、运行配置、数据库或生产模型。

上游：热点/会话运行 + 运营显式反馈 → 采集侧完成脱敏与用途检查 → 现有AnalysisFeedbackCollector来源绑定及幂等收集 → 标签提交及独立二审。

现有转换：EvaluationDatasetFreezer按cutoff读取批准快照 → prepare/upload/persist → PostgreSQL索引 + S3/MinIO不可变JSON。

拟新增：完整修订答案、用途授权、事件/近重复分组与split → 数据台账校验 → SFT/DPO导出；轨迹与奖励契约另行建设。

下游现有：HotNewsOfflineReplayService同输入运行候选/线上/上一实验 → EvaluationGate → ProductionBundle 人工批准、激活或回滚。

配置 / 依赖	对应位置
模型与输入	MODEL_RUNTIME_CONFIG_PATH；PromptRegistry；InferencePort；Schema/Validator/模型版本。
回放与候选	DATA_LOOP_REPLAY_MAX_CONCURRENCY、DATA_LOOP_MAX_CASES_PER_COHORT、HOT_NEWS_RUNTIME_MANIFEST_JSON；候选须已注册。
存储与鉴权	PostgreSQL、S3/MinIO、Temporal；Data Loop网关鉴权。密钥值不进入样本与PDF。
待完成	自动脱敏与导出验收；训练导出/API/迁移；真实数据与二审；检索/对话评测；独立TrainingPort、预算、产物注册；企业质量验收。

测试入口：agent/tests/test_hot_news_evaluation.py、test_dataset_freezer.py、test_offline_replay.py、test_evaluation_gate.py、test_hot_news_dialogue_eval.py。新增导出器需验证：待审/无授权/非train样本拒绝，group跨split阻断，线上渲染一致和完整目标合法。

依据与本次验证：可追溯、可重复生成

代码状态核对日期：2026-10-13。Schema/样例校验通过不等于企业模型质量或正式人工审核。

检查	结果
existing_input_schema	passed
existing_report_schema	passed
reference_and_certainty_checks	passed
ctr_and_components	passed
evidence_cutoff	passed
runtime_rendered_input	passed
human_review	pending
enterprise_model_quality	not_evaluated
business_validator_and_eval_schema	passed

项目依据（均相对下列仓库根目录）

/Users/shi/Project/myProject/NewsAgent

agent/app/schemas/hot_news.py：输入、报告、枚举和必填Memory字段。
agent/app/analytics/hot_score.py：默认四分量确定性计算。
agent/app/model_runtime/core.py：StructuredInferenceService.render_input。
agent/app/schemas/evaluation_dataset.py：标签、血缘与冻结Manifest。
agent/app/services/data_loop/dataset_freezer.py：cutoff及二审快照冻结。
agent/app/services/data_loop/offline_replay.py：双基线与指标真实口径。
agent/app/conversation/query_understanding.py：问句语义与服务端裁定。
agent/evaluation/operations_evolution.py：主线/未来证据防泄漏。

训练格式的官方参考

https://huggingface.co/docs/trl/dataset_formats
https://huggingface.co/docs/trl/sft_trainer
https://huggingface.co/docs/trl/dpo_trainer
https://huggingface.co/docs/trl/grpo_trainer

生成源码：agent/evaluation/render_training_data_guide_pdf.py。CLI→build_examples→validate_examples（可选validate_business）→build_pages→Guide→ReportLab输出PDF；--output/--font/--bold-font控制输出与字体，--validate-only只校验。仅访问项目公开Schema与虚构数据，未读取.env或请求模型。