NewsAgent：人与智能体是如何交互的

基于仓库当前实现整理 · 2026-10-12 · 覆盖对话、工具执行、审批与反馈闭环

一、总体图景：一条受控的双向通道

你（人） ⇄ 聊天页面 /chat（SSE 流式） ⇄ **会话服务**（结构化理解 + 权限校验） ⇄ **受控工具层**（热点查询 / 知识检索 / 数据分析 / 写作 / 反馈沉淀） ⇄ **既有业务引擎**（Temporal Workflow + Python 确定性计算） ⇄ **人工审批门**（研究包 / 提纲 / 终稿 / 评测批准 / 记忆晋升） ⇄ **持久化与审计**（PostgreSQL / MinIO / 轨迹 / 模型调用编号）

核心思想：智能体是**编排入口**，不是新的业务引擎。所有数字由 Python/SQL 确定性计算， 模型只做理解与表达；所有写操作和发布决策最终由人拍板。

二、对话即统一入口

- **持续对话**：消息与轮次保存在 PostgreSQL，支持同会话多轮追问、刷新恢复、断线后用同一请求编号重试（幂等）。
- **安全 SSE 流式**：处理阶段（phase）、工具开始/完成（tool_started / tool_finished）实时推送；答复必须通过结构校验并落库后才分段返回（answer_delta → done），**不是模型原始 token 透传**。
- **上下文管理**：达到长度预算后自动压缩较早对话为摘要，保留近期完整消息；工具引用由 Python 独立提取，摘要不能扩大权限。
- **全链路耗时**：每轮答复下方展示服务端「受理 → 落库」的全链路耗时（一位小数），数据来自持久化时间戳。

三、理解层：模型输出的是"计划"，不是自由文本

每一轮，模型被要求输出一个结构化的 `ConversationPlan`：要么直接回答，要么指定一个工具名和参数。

- **参数白名单**：工具参数经 Pydantic 严格校验；模型不能传身份、SQL、日期场景等越界内容。
- **逐字校验**：热点查询工具要求模型转述的问题与用户原话逐字相等，防止模型替用户"改写需求"。
- **重复调用防护**：同轮重复请求同一工具直接拒绝（denied 轨迹），模型只能解释、不能重试绕过。

四、执行层：受控工具（Hook）体系

工具	做什么	关键约束
query_hot_news	新数仓查询 → 热点 SQL Workflow → 分析	需要 admin；单小时窗口；问题逐字校验；异步分支
search_knowledge	新闻知识分层召回检索	需知识库开启；结果作为不可信证据展示
analyze_hot_news_data	榜单统计分析（概况/分布/对比等）	独立 Python 子进程执行并用同一引擎复核结果
list / read_hot_news	读取已完成热点报告	只读；不接受日期条件（日期需求引导走新查询）

> **编排不重建**：聊天触发的热点查询复用与热点工作台完全相同的 Temporal Workflow——没有第二套 SQL 执行器、没有内部 HTTP 自调用；取消聊天等待不会取消已启动的后台任务。

五、信任层：确定性优先

- 指标、基线、热度、排行全部由 Python/SQL 确定性计算；模型输出必须通过业务 Validator（新闻编号、指标引用、证据编号核对），校验失败拒绝采纳。
- 前端展示的数字与实体 ID 一律来自**工具结果快照**，模型生成的数字不渲染。
- 新闻正文、检索内容、模型输出均视为不可信输入，其中的指令不能改变系统行为或权限。

六、审批层：人握住所有关键闸门

场景	智能体能做	必须由人做
研究写作	生成研究包、提纲、章节、审稿建议	研究包确认 → 提纲确认 → 终稿确认（三个人工 Gate，页面操作）
配置改进（DataLoop）	回放评测、生成对比报告、提出候选	评测批准 / 拒绝 → 激活或回滚 Bundle
长期记忆	提出记忆候选（内容+理由+置信度）	候选晋升为正式长期记忆
内容发布	组装终稿	CMS 发布必须单独人工调用发布接口

> **权力边界**：智能体不可自行修改 Prompt / 热度规则 / 模型版本，不可跳过审批，不可扩大数据访问，不可发布外部内容。

七、反馈闭环：交互沉淀为系统进化

运行结果与人工反馈（采纳 / 驳回 / 修正） → 脱敏反馈案例（关联 run、新闻、配置版本） → 标注二审 → 冻结评测数据集（Golden / 新失败 / 高风险三层） → 当前与候选 Bundle 离线回放 → 确定性评测门禁 → **人工批准 → 人工激活** → 下一次运行生效（可显式回滚）

热点运营决策同样回流：页面上的采纳/驳回/修正直接生成反馈案例，成为评测与策略改进的输入。

八、可观测与审计

- 每轮对话的工具轨迹（名称、状态、参数、结果、错误码）持久化，可展开查看。
- 模型调用编号（model_request_id）随轮次保存，请求 ID 与业务幂等键分离。
- 每轮答复展示全链路耗时；热点运行在同一详情页可核对 SQL 轨迹、候选、榜单与分析。

九、一句话总结

人通过对话提出意图，智能体在受控工具层内执行确定性链路，把结果连同证据、耗时和轨迹透明地交还给人；所有改变系统状态的动作——发布、审批、激活、记忆晋升——的最终按钮始终在人手里。